# PROPOSAL PROJECT
# MACHINE LEARNING
# “Prediksi Tingkat Depresi Mahasiswa Menggunakan Machine Learning”


**Identitas Kelompok**
**Nama (NIM):**

1. **Andika Syuhada (2355301017)**
2. **Mohamad Haziq Dafren (2355301119)**

**Dosen : Dr. Juni Nurma Sari, S.Kom., M.MT.**

**PLP : Rezky Kurniawan, S.Tr.Kom.**

**PROGRAM STUDI TEKNIK INFORMATIKA**
**POLITEKNIK CALTEX RIAU**


**TA 2025 / 2026**

# DAFTAR ISI

**BAB I**.....4
**PENDAHULUAN**..... 4
1.1 Latar Belakang.....4
1.2 Tujuan..... 4
1.3 Manfaat..... 5
1.4 Batasan Masalah..... 5
**BAB II**..... 6
**LANDASAN TEORI**..... 6
**BAB III**.....10
**PERANCANGAN**..... 10
3.1 Exploratory Data Analysis.....10
3.1.1 Melihat data teratas dataset.....10
3.1.2 Melihat tipe data dan nilai kosong (null)..... 10
3.1.3 Memastikan tidak ada duplikasi data..... 11
3.1.4 Melihat jumlah data pada masing–masing kolom.....11
3.1.5 Visualisasi distribusi data per kolom..... 12
3.1.6 Visualisasi variabel dependen (tingkat depresi).....13
3.1.7 Visualisasi hubungan variabel independen dan dependen..... 14
3.1.8 Menggunakan heatmap untuk melihat korelasi antar variabel..... 15
3.1.9 Menggunakan boxplot untuk melihat distribusi antar dua variabel.....16
3.2 Preprocessing..... 17
3.2.1 Memahami isi dan arti setiap kolom pada dataset..... 17
3.2.2 Mengubah label menjadi numerik (Label Encoding)..... 17
3.2.3 Mengubah kolom gender menjadi label numerik..... 17
3.2.4 Melakukan encoding pada kolom kategorikal lainnya..... 18
3.2.5 Pemeriksaan Nilai Kosong (Missing Values)..... 18
3.2.6 Tipe Data Setiap Kolom.....19
3.2.7 Pemeriksaan Kolom Bertipe Numerik.....20
3.2.8 Pemeriksaan Nilai Kosong (Missing Values)..... 20
3.2.9 Statistik Deskriptif Dataset..... 21
3.2.10 Cek Dimensi Dataset.....22
3.2.11 Distribusi Variabel Target (Depression).....23
3.2.12 Visualisasi Distribusi Variabel Target.....23
3.2.13 Rentang Nilai Setiap Kolom.....24

3.2.14 Pemeriksaan Nilai Tidak Wajar (Outlier)..... 25
3.2.15 Analisis Korelasi Antarvariabel..... 25
3.2.16 Kesimpulan Tahap Preprocessing..... 27
3.3 Perancangan Model..... 28
3.3.1 Import Library untuk Modeling..... 28
3.3.2 Pemisahan fitur dan target..... 29
3.3.3 Split data..... 29
3.3.4 Pemeriksaan Proporsi Kelas pada Data Training dan Testing..... 30
3.4 Feature Scalling..... 30
3.4.1 Normalisasi Data..... 30
3.4.2 Evaluasi Hasil Normalisasi..... 31
3.4.3 Visualisasi Perbandingan Sebelum dan Sesudah Scaling..... 32
3.5 Training Model..... 32
3.5.1 Pelatihan Model Logistic Regression..... 32
3.5.2 Evaluasi dengan Cross-Validation..... 33
3.5.3 Koefisien Fitur..... 33
3.5.4 Visualisasi Pengaruh Fitur terhadap Prediksi Depression..... 34
3.6 Tahap Prediksi..... 35
3.6.1 Proses Prediksi Data Testing..... 35
3.6.2 Evaluasi Hasil Prediksi Awal..... 36
3.7 Evaluasi Model..... 36
3.7.1 Evaluasi Kinerja Model..... 36
3.7.2 Analisis Confusion Matrix..... 37
3.8 Hasil..... 38
3.8.1 Visualisasi Confusion Matrix..... 38
3.8.2 Laporan Klasifikasi..... 39
3.8.3 Analisis Kesalahan Prediksi (False Positives)..... 40
3.8.4 Analisis Kesalahan Prediksi (False Negatives)..... 40
3.8.5 Visualisasi Metrik Evaluasi..... 41
3.8.6 Visualisasi ROC Curve..... 42
3.8.7 Visualisasi Distribusi Probabilitas Prediksi..... 43
3.8.8 Perbandingan dengan Model Baseline..... 44
3.8.9 Visualisasi Perbandingan Model dan Baseline..... 45
3.8.10 Ringkasan Hasil Penelitian..... 45
3.8.11 Proses penyimpanan model..... 46
3.9 Perbandingan Model..... 48
3.9.1 Model Random Forest..... 48
3.9.2 Evaluasi Model Random Forest..... 48

3.9.3 Visualisasi Confusion Matrix Model Random Forest.....49
3.9.2 Model Support Vector Machine.....50
3.9.2 Evaluasi Model Support Vector Machine.....51
3.9.4 Perbandingan Performa Semua Model.....53
**DAFTAR PUSTAKA.....54**

# BAB I

# PENDAHULUAN

## 1.1 Latar Belakang

Masalah kesehatan mental, khususnya depresi, semakin banyak dialami oleh mahasiswa seiring dengan meningkatnya tekanan akademik, beban tugas, dan tantangan kehidupan sosial. Kondisi ini sering kali tidak terdeteksi sejak dini karena keterbatasan alat ukur atau kesadaran individu terhadap kesehatannya sendiri. Padahal, depresi yang tidak tertangani dapat berdampak negatif terhadap prestasi akademik, hubungan sosial, serta kualitas hidup secara keseluruhan.

Dengan berkembangnya teknologi machine learning, kini dimungkinkan untuk menganalisis berbagai faktor penyebab depresi secara data-driven. Melalui pemrosesan data terkait usia, tekanan akademik, jam tidur, kebiasaan makan, hingga dukungan keluarga, model machine learning dapat membantu mengidentifikasi mahasiswa yang memiliki potensi mengalami depresi.

Penelitian ini menggunakan dataset Student Mental Health Assessment yang berisi berbagai indikator gaya hidup dan tekanan akademik mahasiswa. Proyek ini akan membangun model prediksi tingkat depresi menggunakan algoritma Logistic Regression sebagai pendekatan sederhana untuk memahami hubungan antar variabel. Model ini diharapkan dapat menjadi dasar untuk pengembangan fitur pendukung pada aplikasi kampus yang membantu mahasiswa dan pihak konselor mengenali risiko depresi secara lebih cepat dan akurat.

## 1.2 Tujuan

Penelitian ini bertujuan untuk membangun model machine learning yang mampu memprediksi tingkat depresi mahasiswa berdasarkan faktor-faktor akademik dan gaya hidup yang terdapat pada dataset. Melalui analisis variabel seperti tekanan akademik, durasi tidur, pola makan, stres keuangan, dan riwayat keluarga, penelitian ini diharapkan dapat memberikan pemahaman tentang bagaimana faktor-faktor tersebut berkaitan dengan kondisi mental mahasiswa. Hasil penelitian ini juga diharapkan dapat memberikan dasar pengembangan sistem

pendukung keputusan di lingkungan kampus untuk pemantauan kesejahteraan mental mahasiswa.

## 1.3 Manfaat

1. Memberikan gambaran hubungan antara faktor akademik, gaya hidup, dan tingkat depresi mahasiswa.
2. Menjadi referensi awal bagi penelitian lanjutan dalam bidang machine learning untuk kesehatan mental.
3. Membantu pihak kampus dalam memahami pola umum terkait faktor penyebab depresi pada mahasiswa.
4. Meningkatkan kesadaran mahasiswa terhadap pentingnya menjaga kesehatan mental di tengah aktivitas akademik.

## 1.4 Batasan Masalah

Penelitian ini berfokus pada faktor akademik dan gaya hidup sebagai variabel utama dalam memprediksi kesehatan mental mahasiswa.

1. Penelitian ini berfokus pada prediksi tingkat depresi mahasiswa dengan menggunakan faktor akademik, gaya hidup, serta faktor psikologis dan sosial sebagai variabel utama.
2. Algoritma yang digunakan adalah Logistic Regression, karena kesederhanaan dan interpretabilitasnya dalam memahami pengaruh tiap faktor terhadap depresi.
3. Dataset utama berasal dari Student Mental Health Assessment Dataset (https://www.kaggle.com/datasets/ikynahidwin/depression-student-dataset/data ) dan akan diuji tambahan data melalui survei mahasiswa Politeknik Caltex Riau.
4. Penelitian ini tidak mencakup diagnosis medis atau rekomendasi psikologis, melainkan fokus pada analisis prediktif berbasis data.

# BAB II

# LANDASAN TEORI

## 2.1 Machine Learning

Machine Learning (ML) merupakan salah satu cabang dari kecerdasan buatan (Artificial Intelligence) yang memungkinkan sistem komputer untuk belajar secara otomatis dari data tanpa perlu diprogram secara eksplisit untuk setiap tugas tertentu. Dengan kata lain, machine learning memungkinkan komputer untuk menemukan pola dan membuat prediksi berdasarkan pengalaman atau data historis yang diberikan (Jordan & Mitchell, *Science*, 2015). Hal ini menjadikan machine learning sangat relevan untuk berbagai bidang seperti kesehatan, keuangan, industri, hingga analisis psikologis.

Menurut Liu et al. (2023) dalam *Journal of Affective Disorders*, machine learning telah terbukti efektif dalam menganalisis gejala psikologis seperti depresi karena kemampuannya mengenali pola dari data yang kompleks dan multidimensi. Sistem machine learning mampu mengidentifikasi korelasi antar variabel yang tidak mudah terlihat oleh manusia secara manual. Oleh karena itu, dalam konteks penelitian ini, penggunaan machine learning dinilai tepat untuk membantu mengklasifikasikan status depresi individu berdasarkan data kuesioner atau faktor risiko psikologis lainnya.

Tidak hanya itu, machine learning memiliki keunggulan dalam hal skalabilitas dan akurasi prediksi. Semakin besar jumlah data yang digunakan, semakin baik model machine learning dalam memahami pola dan menghasilkan prediksi yang lebih akurat. Hal ini menjadi nilai tambah yang sangat penting dalam penelitian kesehatan mental, mengingat data terkait depresi sering kali bersifat subjektif dan bervariasi antar individu. Dengan demikian, machine learning dapat menjadi alat analisis yang tidak hanya objektif, tetapi juga adaptif terhadap data dalam jumlah besar.

## 2.2 Depresi

Depresi merupakan salah satu gangguan kesehatan mental yang ditandai oleh perasaan sedih berkepanjangan, kehilangan minat terhadap aktivitas yang sebelumnya menyenangkan,

serta gangguan pada pola tidur, konsentrasi, dan motivasi. WHO (2021) mendefinisikan depresi sebagai kondisi gangguan mental yang memengaruhi pikiran, perasaan, dan perilaku seseorang sehingga menyebabkan penurunan kualitas hidup secara signifikan. Depresi tidak hanya berdampak pada aspek emosional, tetapi juga pada aspek fisik, sosial, dan produktivitas seseorang di lingkungan kerja maupun akademik.

Menurut Summerfield (2015) dalam *British Journal of Psychiatry*, depresi bukan sekadar suasana hati yang buruk, tetapi merupakan gangguan psikopatologis yang dapat mengganggu kinerja individu dalam kehidupan sehari-hari. Gejala depresi sering kali tidak disadari oleh penderitanya karena muncul secara bertahap dan bersifat subjektif. Hal inilah yang menyebabkan deteksi dini depresi menjadi tantangan besar, terutama pada kelompok usia produktif seperti mahasiswa dan pekerja.

Penelitian terbaru oleh Liu et al. (2024) menunjukkan bahwa prevalensi depresi di kalangan mahasiswa meningkat secara signifikan pascapandemi COVID-19. Faktor-faktor seperti tekanan akademik, masalah finansial, isolasi sosial, dan kecemasan masa depan menjadi pemicu utama munculnya gejala depresi. Oleh karena itu, penting untuk memiliki sistem pendeteksian depresi yang cepat, objektif, dan akurat agar intervensi dapat dilakukan sedini mungkin.

Dalam konteks penelitian ini, depresi menjadi variabel target (variabel dependen) yang akan diklasifikasikan apakah seseorang berada dalam kategori tidak depresi, depresi ringan, atau depresi sedang/berat. Proses klasifikasi tersebut akan dianalisis menggunakan algoritma machine learning, sehingga hasilnya diharapkan lebih objektif dibandingkan analisis manual atau observasi psikologis tradisional.

### 2.3 Exploratory Data Analysis

Exploratory Data Analysis (EDA) merupakan tahap awal dalam proses analisis data yang bertujuan untuk memahami struktur, karakteristik, serta pola yang terdapat di dalam dataset. EDA digunakan untuk mengeksplorasi data sebelum dilakukan pemodelan, sehingga peneliti dapat menemukan hubungan antar variabel, mendeteksi anomali, data kosong, serta distribusi nilai dari tiap fitur (Tukey, *Journal of the American Statistical Association*, 1977). Tahapan ini

sangat penting agar keputusan yang diambil selanjutnya berbasis pemahaman yang akurat terhadap data yang digunakan.

Menurut García et al. (2022), EDA tidak hanya sekadar menampilkan statistik deskriptif seperti mean, median, atau modus, tetapi juga memanfaatkan visualisasi data seperti histogram, heatmap, dan bar chart untuk memperjelas pola yang sulit terlihat secara numerik. Dalam konteks penelitian deteksi depresi, EDA berperan untuk memahami persebaran tingkat depresi berdasarkan gender, usia, tingkat pendidikan, atau variabel psikologis lainnya. Misalnya, melalui EDA dapat diketahui apakah terdapat kecenderungan nilai ekstrim (outliers) yang harus ditangani sebelum proses pemodelan.

Melalui tahap EDA, peneliti juga dapat memutuskan strategi preprocessing yang tepat, memilih fitur (feature selection), serta memastikan kualitas dataset. Dengan demikian, EDA tidak hanya membantu dalam eksplorasi, tetapi juga mencegah kesalahan interpretasi dan meningkatkan efektivitas algoritma machine learning pada tahap berikutnya.

### 2.4 Data Preprocessing

Data preprocessing adalah tahapan krusial dalam machine learning yang bertujuan untuk membersihkan, menyiapkan, dan mengubah data mentah menjadi data yang siap digunakan untuk pemodelan. Data mentah umumnya mengandung nilai kosong (missing values), data duplikat, noise, atau variabel yang tidak relevan. Kotsiantis et al. (2007) dalam *Artificial Intelligence Review* menyatakan bahwa kualitas output model machine learning sangat bergantung pada kualitas data input yang telah melalui proses preprocessing yang baik.

Tahapan preprocessing dapat mencakup beberapa proses, seperti:

- **Data cleaning** (menghapus duplikasi, menangani missing values)

- **Encoding** (mengubah data kategorikal menjadi numerik, seperti one-hot encoding atau label encoding)

- **Normalization / Standardization** (menyamakan skala antar fitur agar tidak bias)

- **Feature selection** (memilih fitur yang paling relevan agar model lebih efisien dan akurat)

Dalam konteks deteksi depresi, preprocessing sangat penting karena data psikologis umumnya tidak konsisten. Misalnya, ada responden yang melewatkan pertanyaan, memberikan jawaban ekstrem, atau menggunakan format berbeda (angka vs teks). Dengan preprocessing yang tepat, model machine learning dapat bekerja secara optimal dan memberikan hasil klasifikasi yang akurat serta stabil.

**2.5 Algoritma Logistic Regression**

Logistic Regression adalah salah satu algoritma supervised learning yang paling populer dan banyak digunakan untuk tugas klasifikasi biner, seperti menentukan apakah seseorang termasuk kategori depresi atau tidak depresi. Menurut Hosmer & Lemeshow (2013) dalam *Journal of Applied Logistic Regression*, algoritma ini bekerja dengan memodelkan probabilitas suatu kejadian melalui fungsi sigmoid, yang menghasilkan nilai antara 0 hingga 1. Nilai tersebut kemudian dipetakan ke dalam kelas tertentu berdasarkan threshold (misalnya, 0.5 sebagai batas klasifikasi).

Kelebihan logistic regression adalah model ini memiliki interpretabilitas yang tinggi, sehingga peneliti dapat memahami pengaruh setiap variabel terhadap peluang seseorang mengalami depresi. Selain itu, Hosmer (2013) menegaskan bahwa logistic regression sangat efisien digunakan pada dataset berskala kecil hingga menengah dan tidak rentan overfitting jika preprocessing dilakukan dengan baik.

Dalam penelitian ini, logistic regression dipilih karena stabil, sederhana, dan mampu memberikan hasil klasifikasi berbasis probabilitas. Hal ini sangat penting dalam studi deteksi depresi, karena hasil klasifikasi bukan hanya sekadar “ya atau tidak”, tetapi juga dapat menunjukkan tingkat risiko seseorang terhadap depresi, sehingga memungkinkan tindakan intervensi yang lebih tepat sasaran.

**Progress Project III - 19/11/2025**

# BAB III

# PERANCANGAN

## 3.1 Exploratory Data Analysis

### 3.1.1 Melihat data teratas dataset

Langkah pertama adalah menampilkan beberapa baris teratas dari dataset (biasanya menggunakan fungsi head()) untuk mendapatkan gambaran awal mengenai struktur data. Dari sini kita bisa langsung mengetahui kolom apa saja yang tersedia beserta contoh isi datanya, sehingga mempermudah proses eksplorasi selanjutnya.

| | Gender | Age | Academic Pressure | Study Satisfaction | Sleep Duration | Dietary Habits | Have you ever had suicidal thoughts ? | Study Hours | Financial Stress | Family History of Mental Illness | Depression |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | Male | 28 | 2.0 | 4.0 | 7-8 hours | Moderate | Yes | 9 | 2 | Yes | No |
| 1 | Male | 28 | 4.0 | 5.0 | 5-6 hours | Healthy | Yes | 7 | 1 | Yes | No |
| 2 | Male | 25 | 1.0 | 3.0 | 5-6 hours | Unhealthy | Yes | 10 | 4 | No | Yes |
| 3 | Male | 23 | 1.0 | 4.0 | More than 8 hours | Unhealthy | Yes | 7 | 2 | Yes | No |
| 4 | Female | 31 | 1.0 | 5.0 | More than 8 hours | Healthy | Yes | 4 | 2 | Yes | No |

### 3.1.2 Melihat tipe data dan nilai kosong (null)

Pemeriksaan tipe data pada setiap kolom dilakukan untuk memastikan bahwa tidak ada kolom yang memiliki tipe data yang tidak sesuai, misalnya kolom numerik yang terbaca sebagai string. Selain itu, dilakukan pengecekan nilai null atau missing values untuk menilai kualitas data dan menentukan apakah perlu dilakukan proses cleaning seperti imputasi atau penghapusan data.

```
=== Informasi Dataset ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 502 entries, 0 to 501
Data columns (total 11 columns):
 #   Column                                  Non-Null Count  Dtype
---  ------                                  --------------  -----
 0   Gender                                  502 non-null    object
 1   Age                                     502 non-null    int64
 2   Academic Pressure                       502 non-null    float64
 3   Study Satisfaction                      502 non-null    float64
 4   Sleep Duration                          502 non-null    object
 5   Dietary Habits                          502 non-null    object
 6   Have you ever had suicidal thoughts ?   502 non-null    object
 7   Study Hours                             502 non-null    int64
 8   Financial Stress                        502 non-null    int64
 9   Family History of Mental Illness        502 non-null    object
 10  Depression                              502 non-null    object
dtypes: float64(2), int64(3), object(6)
memory usage: 43.3+ KB
```

3.1.3 Memastikan tidak ada duplikasi data

Pengecekan data duplikat dilakukan agar dataset tetap bersih dan valid. Adanya data yang tercatat lebih dari satu kali dapat menyebabkan bias dalam proses analisis maupun pemodelan, sehingga baris data duplikat harus dihapus bila ditemukan.

```
=== Missing Values per Kolom ===
Gender                                    0
Age                                       0
Academic Pressure                         0
Study Satisfaction                        0
Sleep Duration                            0
Dietary Habits                            0
Have you ever had suicidal thoughts ?     0
Study Hours                               0
Financial Stress                          0
Family History of Mental Illness          0
Depression                                0
dtype: int64

=== Jumlah Data Duplikat ===
0
```

3.1.4 Melihat jumlah data pada masing–masing kolom

Dilakukan analisis terhadap jumlah atau sebaran data pada tiap kolom untuk memahami karakteristik dataset secara menyeluruh. Hal ini membantu dalam mengidentifikasi apakah ada ketidakseimbangan kelas atau kolom dengan distribusi data yang tidak normal.

```
=== Informasi Data & Jumlah Nilai Unik ===
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 502 entries, 0 to 501
Data columns (total 11 columns):
 #   Column                                 Non-Null Count  Dtype
---  ------                                 --------------  -----
 0   Gender                                 502 non-null    object
 1   Age                                    502 non-null    int64
 2   Academic Pressure                      502 non-null    float64
 3   Study Satisfaction                     502 non-null    float64
 4   Sleep Duration                         502 non-null    object
 5   Dietary Habits                         502 non-null    object
 6   Have you ever had suicidal thoughts ?  502 non-null    object
 7   Study Hours                            502 non-null    int64
 8   Financial Stress                       502 non-null    int64
 9   Family History of Mental Illness       502 non-null    object
 10  Depression                             502 non-null    object
dtypes: float64(2), int64(3), object(6)
memory usage: 43.3+ KB
None
Gender: 2 unique values
Age: 17 unique values
Academic Pressure: 5 unique values
Study Satisfaction: 5 unique values
Sleep Duration: 4 unique values
Dietary Habits: 3 unique values
Have you ever had suicidal thoughts ?: 2 unique values
Study Hours: 13 unique values
Financial Stress: 5 unique values
Family History of Mental Illness: 2 unique values
Depression: 2 unique values
```

3.1.5 Visualisasi distribusi data per kolom

Membuat visualisasi jumlah data pada setiap kolom untuk memahami distribusi nilai yang ada. Visualisasi seperti bar chart atau histogram akan membantu membedakan apakah data bersifat seimbang, dominan di satu nilai tertentu, atau memiliki sebaran yang ekstrem.

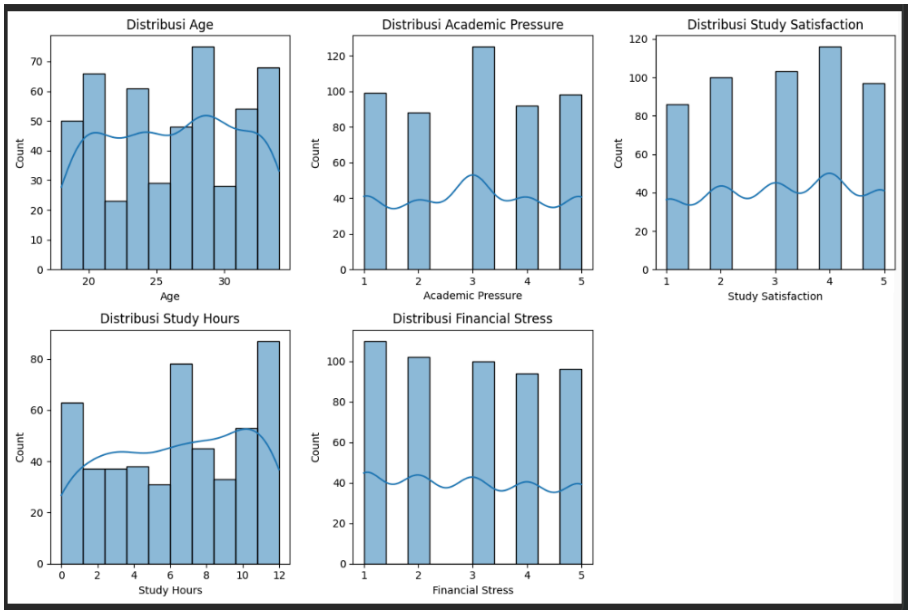


3.1.6 Visualisasi variabel dependen (tingkat depresi)

Pada tahap ini dilakukan visualisasi terhadap variabel target/dependen untuk melihat proporsi kategori yang ada. Dari grafik yang ditampilkan, dapat terlihat apakah jumlah individu yang mengalami depresi lebih tinggi dibandingkan yang tidak mengalami depresi.

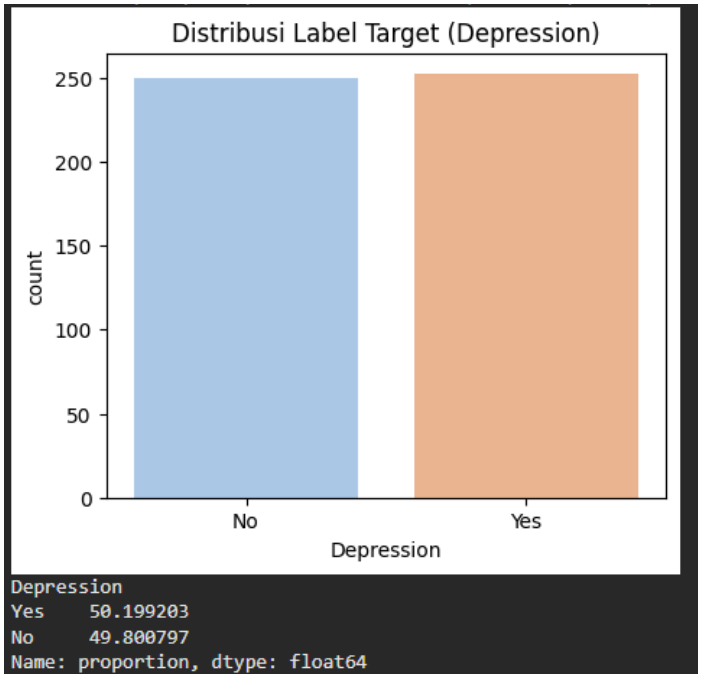


3.1.7 Visualisasi hubungan variabel independen dan dependen

Visualisasi dibuat untuk menganalisis hubungan antara variabel bebas dengan variabel target. Tujuannya adalah untuk mengamati seberapa besar pengaruh setiap variabel independen terhadap potensi terjadinya depresi, serta untuk mendeteksi pola atau kecenderungan tertentu dalam data.

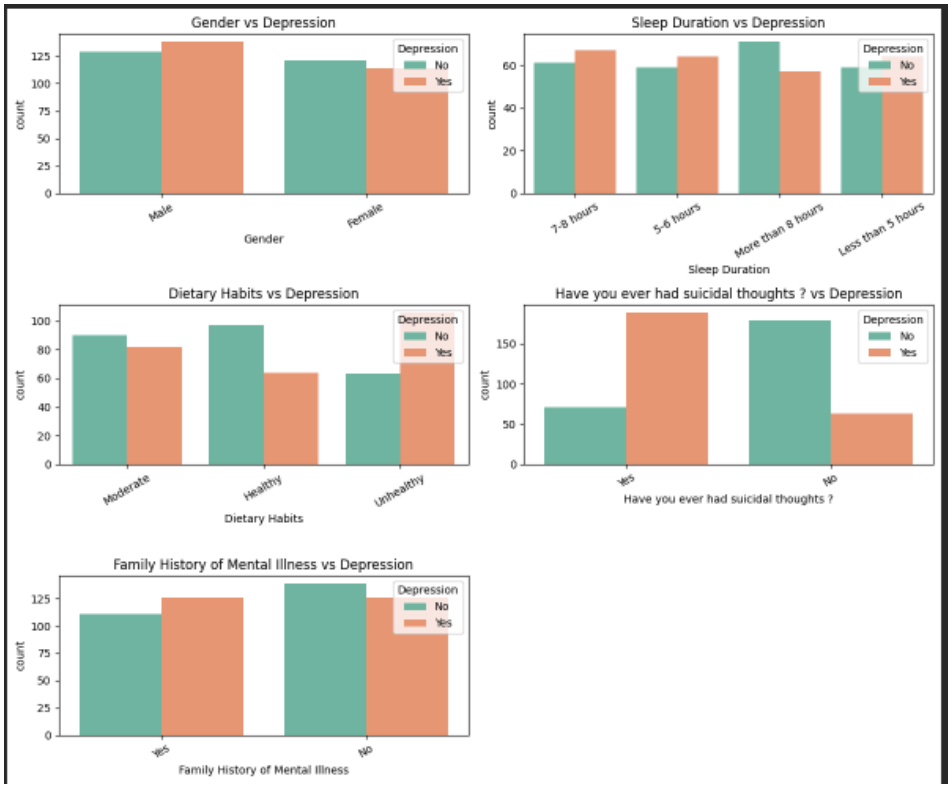


3.1.8 Menggunakan heatmap untuk melihat korelasi antar variabel

Heatmap digunakan sebagai visualisasi korelasi antar variabel numerik. Nilai korelasi yang mendekati +1 mengindikasikan hubungan yang sangat kuat dan searah, sedangkan nilai mendekati -1 menunjukkan hubungan yang kuat tetapi berlawanan arah. Hasil ini sangat penting dalam pemilihan fitur.

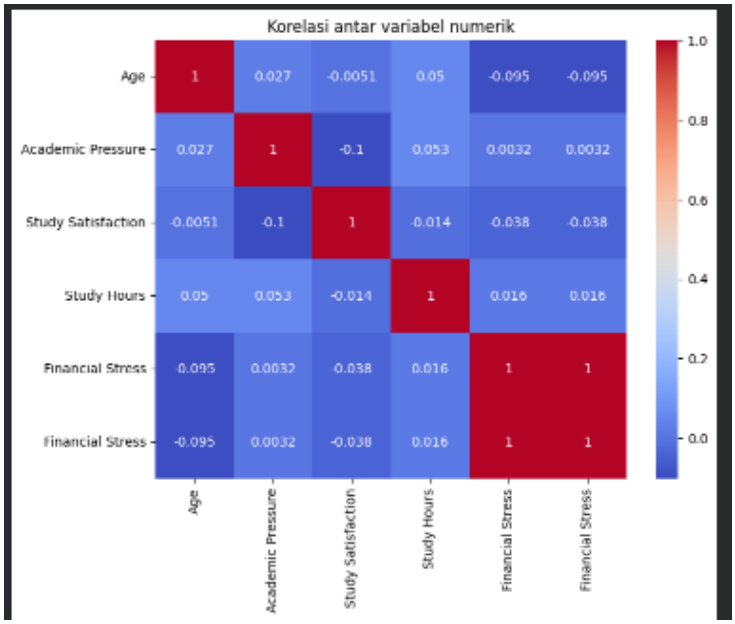


3.1.9 Menggunakan boxplot untuk melihat distribusi antar dua variabel

Boxplot digunakan untuk melihat rentang data, nilai median, outlier, serta sebaran data dari dua kolom sekaligus. Ini membantu dalam memahami perbedaan distribusi antara kelompok, misalnya perbandingan tingkat depresi berdasarkan durasi tidur.

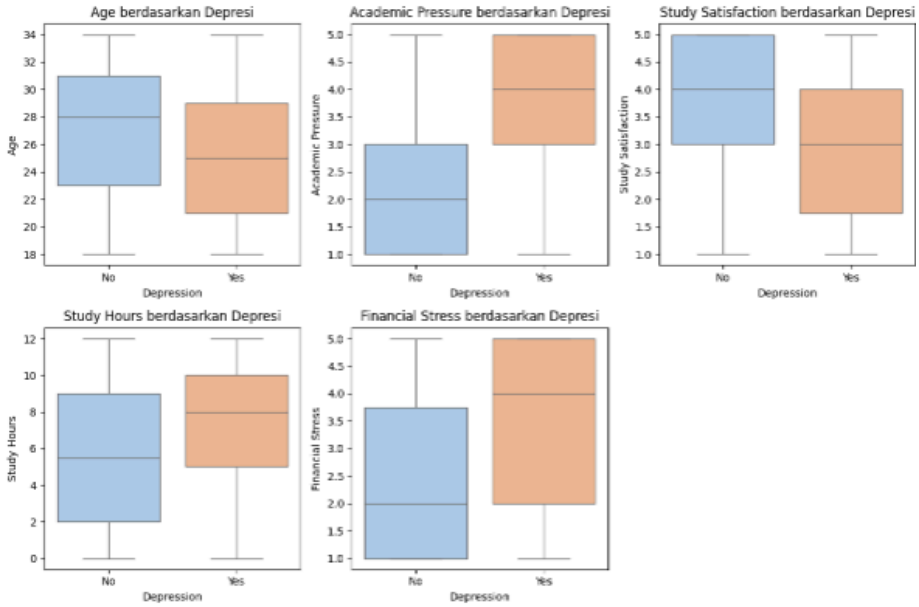

## 3.2 Preprocessing

### 3.2.1 Memahami isi dan arti setiap kolom pada dataset

Tahap ini bertujuan untuk memahami peran masing-masing kolom secara semantik, seperti apakah data bersifat kategorik, numerik, ordinal, atau biner, agar proses pengolahan data berikutnya seperti encoding dan normalisasi dapat dilakukan dengan tepat.

```
df.head()
```

| | Gender | Age | Academic Pressure | Study Satisfaction | Sleep Duration | Dietary Habits | Have you ever had suicidal thoughts ? | Study Hours | Financial Stress | Family History of Mental Illness | Depression |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | Male | 28 | 2.0 | 4.0 | 7-8 hours | Moderate | Yes | 9 | 2 | Yes | No |
| 1 | Male | 28 | 4.0 | 5.0 | 5-6 hours | Healthy | Yes | 7 | 1 | Yes | No |
| 2 | Male | 25 | 1.0 | 3.0 | 5-6 hours | Unhealthy | Yes | 10 | 4 | No | Yes |
| 3 | Male | 23 | 1.0 | 4.0 | More than 8 hours | Unhealthy | Yes | 7 | 2 | Yes | No |
| 4 | Female | 31 | 1.0 | 5.0 | More than 8 hours | Healthy | Yes | 4 | 2 | Yes | No |

### 3.2.2 Mengubah label menjadi numerik (Label Encoding)

Label atau data kategorik pada variabel target diubah ke dalam bentuk numerik agar dapat diproses oleh algoritma machine learning. Misalnya, "Yes" menjadi 1 dan "No" menjadi 0.

```
# Ubah label target menjadi numerik
df['Depression'] = df['Depression'].map({'Yes': 1, 'No': 0})
```

### 3.2.3 Mengubah kolom gender menjadi label numerik

Kolom gender diubah menjadi angka, dengan contoh penetapan label 1 untuk laki-laki dan 2 untuk perempuan. Hal ini diperlukan karena sebagian besar algoritma machine learning tidak dapat membaca data berbentuk teks langsung.

```python
# Pastikan semua data di Gender jadi string dulu
df['Gender'] = df['Gender'].astype(str).str.strip().str.lower()

# Mapping gender
df['Gender'] = df['Gender'].map({
    'male': 1,
    'female': 0
})

# Jika masih ada kategori lain (misalnya 'other'), jadikan NaN
df['Gender'] = df['Gender'].replace({'nan': np.nan})

# Cek hasilnya
print("=== Unique values in Gender after encoding ===")
print(df['Gender'].value_counts(dropna=False))
```

```
=== Unique values in Gender after encoding ===
Gender
1    267
0    235
Name: count, dtype: int64
```

3.2.4 Melakukan encoding pada kolom kategorikal lainnya

Beberapa kolom seperti Sleep Duration, Dietary Habits, Pikiran Bunuh Diri, dan Riwayat Penyakit Mental juga diubah menjadi bentuk angka menggunakan teknik encoding. Konversi ini wajib dilakukan karena algoritma seperti Logistic Regression hanya dapat menerima input dalam bentuk numerik.

| | Gender | Age | Academic Pressure | Study Satisfaction | Sleep Duration | Dietary Habits | Have you ever had suicidal thoughts ? | Study Hours | Financial Stress | Family History of Mental Illness | Depression |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 0 | 1 | 28 | 2.0 | 4.0 | 7.5 | 1 | 1 | 9 | 2 | 1 | 0 |
| 1 | 1 | 28 | 4.0 | 5.0 | 5.5 | 2 | 1 | 7 | 1 | 1 | 0 |
| 2 | 1 | 25 | 1.0 | 3.0 | 5.5 | 0 | 1 | 10 | 4 | 0 | 1 |
| 3 | 1 | 23 | 1.0 | 4.0 | 9.0 | 0 | 1 | 7 | 2 | 1 | 0 |
| 4 | 0 | 31 | 1.0 | 5.0 | 9.0 | 2 | 1 | 4 | 2 | 1 | 0 |

3.2.5 Pemeriksaan Nilai Kosong (Missing Values)

Berdasarkan hasil yang ditampilkan pada tabel, seluruh kolom menunjukkan nilai 0, yang berarti tidak ada data yang hilang atau kosong pada dataset. Hal ini menunjukkan bahwa dataset telah bersih dan siap digunakan untuk tahap analisis berikutnya tanpa perlu melakukan proses data imputation atau penghapusan baris data.

| | |
|---|---|
| Gender | 0 |
| Age | 0 |
| Academic Pressure | 0 |
| Study Satisfaction | 0 |
| Sleep Duration | 0 |
| Dietary Habits | 0 |
| Have you ever had suicidal thoughts ? | 0 |
| Study Hours | 0 |
| Financial Stress | 0 |
| Family History of Mental Illness | 0 |
| Depression | 0 |

3.2.6 Tipe Data Setiap Kolom

Hasil pemeriksaan menunjukkan bahwa semua kolom dalam dataset sudah memiliki tipe data numerik, yaitu int64 dan float64. Dari sini dapat dipahami bahwa setiap data sudah dalam bentuk angka, sehingga mudah diolah dan dianalisis lebih lanjut. Kolom dengan tipe bilangan bulat (int64) umumnya berisi data kategori yang telah diubah menjadi angka, sedangkan kolom dengan tipe desimal (float64) berisi nilai yang memiliki rentang atau skala tertentu seperti tekanan akademik dan kepuasan belajar. Dengan struktur data yang sudah sesuai ini, proses analisis selanjutnya dapat dilakukan tanpa hambatan.

```
============================================================
TIPE DATA SETIAP KOLOM
============================================================
Gender                                        int64
Age                                           int64
Academic Pressure                           float64
Study Satisfaction                          float64
Sleep Duration                              float64
Dietary Habits                                int64
Have you ever had suicidal thoughts ?         int64
Study Hours                                   int64
Financial Stress                              int64
Family History of Mental Illness              int64
Depression                                    int64
dtype: object
```

3.2.7 Pemeriksaan Kolom Bertipe Numerik

Pada tahap ini dilakukan pengecekan untuk memastikan bahwa seluruh kolom dalam dataset sudah bertipe numerik. Hasil yang ditampilkan menunjukkan bahwa semua kolom telah berformat angka dan tidak ada kolom yang masih berupa teks atau kategori non-numerik. Hal ini menandakan bahwa data telah siap digunakan untuk proses analisis statistik maupun pemodelan machine learning, karena sebagian besar algoritma hanya dapat membaca input dalam bentuk numerik.

```
# Cek apakah semua kolom sudah numerik
non_numeric = df.select_dtypes(exclude=['number']).columns.tolist()
if len(non_numeric) == 0:
    print("✅ Semua kolom sudah bertipe numerik!")
else:
    print(f"⚠️ Kolom yang belum numerik: {non_numeric}")

✅ Semua kolom sudah bertipe numerik!
```

3.2.8 Pemeriksaan Nilai Kosong (Missing Values)

Hasil pemeriksaan menunjukkan bahwa semua kolom dalam dataset memiliki nilai **0** pada jumlah *missing values*, artinya tidak ada data yang hilang atau kosong. Kondisi ini sangat baik karena menunjukkan bahwa dataset sudah bersih dan lengkap, sehingga tidak diperlukan proses tambahan seperti pengisian nilai yang hilang

(*imputation*) atau penghapusan data. Dengan data yang utuh, analisis dapat dilakukan dengan lebih akurat tanpa khawatir adanya bias akibat data yang tidak lengkap.

```
Missing Values per Kolom:
Gender                                    0
Age                                       0
Academic Pressure                         0
Study Satisfaction                        0
Sleep Duration                            0
Dietary Habits                            0
Have you ever had suicidal thoughts ?     0
Study Hours                               0
Financial Stress                          0
Family History of Mental Illness          0
Depression                                0
dtype: int64
```

3.2.9 Statistik Deskriptif Dataset

Dari hasil statistik deskriptif, dapat dilihat gambaran umum mengenai sebaran nilai pada setiap kolom dalam dataset. Terlihat bahwa jumlah data untuk setiap variabel berjumlah 502 baris, menandakan tidak ada data yang hilang. Nilai rata-rata (*mean*) dan standar deviasi (*std*) membantu memahami pola umum dan tingkat variasi antar data, misalnya tekanan akademik rata-rata berada di sekitar angka 3, sedangkan durasi tidur rata-rata sekitar 6,5 jam. Beberapa kolom seperti *Depression* dan *Have you ever had suicidal thoughts?* menunjukkan nilai minimum 0 dan maksimum 1, yang berarti data tersebut bersifat biner. Melalui ringkasan ini, dapat disimpulkan bahwa dataset memiliki sebaran data yang wajar dan konsisten untuk digunakan dalam tahap analisis selanjutnya.

```
Statistik Deskriptif Dataset:
           Gender         Age  Academic Pressure  Study Satisfaction  \
count  502.000000  502.000000         502.000000          502.000000
mean     0.531873   26.241036           3.003984            3.075697
std      0.499481    4.896501           1.390007            1.373490
min      0.000000   18.000000           1.000000            1.000000
25%      0.000000   22.000000           2.000000            2.000000
50%      1.000000   26.500000           3.000000            3.000000
75%      1.000000   30.000000           4.000000            4.000000
max      1.000000   34.000000           5.000000            5.000000

       Sleep Duration  Dietary Habits  Have you ever had suicidal thoughts ?  \
count      502.000000      502.000000                              502.000000
mean         6.534861        0.984064                                0.517928
std          1.905523        0.811436                                0.500177
min          4.000000        0.000000                                0.000000
25%          5.500000        0.000000                                0.000000
50%          7.500000        1.000000                                1.000000
75%          9.000000        2.000000                                1.000000
max          9.000000        2.000000                                1.000000

       Study Hours  Financial Stress  Family History of Mental Illness  \
count   502.000000        502.000000                        502.000000
mean      6.404382          2.928287                          0.472112
std       3.742434          1.425053                          0.499720
min       0.000000          1.000000                          0.000000
25%       3.000000          2.000000                          0.000000
50%       7.000000          3.000000                          0.000000
75%      10.000000          4.000000                          1.000000
max      12.000000          5.000000                          1.000000

       Depression
count  502.000000
mean     0.501992
std      0.500495
min      0.000000
25%      0.000000
50%      1.000000
75%      1.000000
max      1.000000
```

3.2.10 Cek Dimensi Dataset

Hasil pengecekan menunjukkan bahwa dataset memiliki 502 baris dan 11 kolom. Setiap baris merepresentasikan satu sampel responden, sedangkan kolom berisi berbagai fitur seperti tekanan akademik, kepuasan belajar, durasi tidur, serta satu kolom target yaitu tingkat depresi. Dengan jumlah data yang cukup banyak dan fitur yang beragam, dataset ini dianggap representatif untuk dilakukan analisis dan pemodelan machine learning secara lebih mendalam.

```
# Cek dimensi dataset
print(f"Dimensi dataset: {df.shape}")
print(f"Jumlah baris (sampel): {df.shape[0]}")
print(f"Jumlah kolom (fitur + target): {df.shape[1]}")

Dimensi dataset: (502, 11)
Jumlah baris (sampel): 502
Jumlah kolom (fitur + target): 11
```

### 3.2.11 Distribusi Variabel Target (Depression)

Hasil analisis menunjukkan bahwa distribusi data antara kategori Tidak Depresi (0) dan Depresi (1) hampir seimbang, dengan persentase masing-masing sekitar 49,80% dan 50,20%. Keseimbangan ini merupakan kondisi yang baik karena model machine learning nantinya tidak akan cenderung berat sebelah terhadap salah satu kelas. Dengan proporsi data yang seimbang, proses pelatihan model akan lebih adil dan hasil prediksi menjadi lebih akurat.

```
# Persentase distribusi target
print("Persentase Distribusi Depression:")
dist_pct = df['Depression'].value_counts(normalize=True) * 100
print(f"Tidak Depresi (0): {dist_pct[0]:.2f}%")
print(f"Depresi (1): {dist_pct[1]:.2f}%")

Persentase Distribusi Depression:
Tidak Depresi (0): 49.80%
Depresi (1): 50.20%
```

### 3.2.12 Visualisasi Distribusi Variabel Target

Visualisasi menggunakan diagram batang memperlihatkan perbandingan jumlah mahasiswa yang mengalami depresi (1) dan yang tidak mengalami depresi (0). Hasil grafik menunjukkan bahwa sebanyak 252 mahasiswa teridentifikasi mengalami depresi, sedangkan 250 mahasiswa tidak mengalami depresi. Perbedaan jumlah yang sangat kecil ini menandakan bahwa data target memiliki distribusi yang seimbang. Warna hijau merepresentasikan kategori “Ya (Depresi)” dan warna merah untuk “Tidak (Tidak Depresi)”, sehingga memudahkan dalam melihat proporsi antar kategori. Grafik ini membantu memastikan bahwa model nantinya tidak akan bias terhadap salah satu kelas karena distribusi data yang relatif merata.

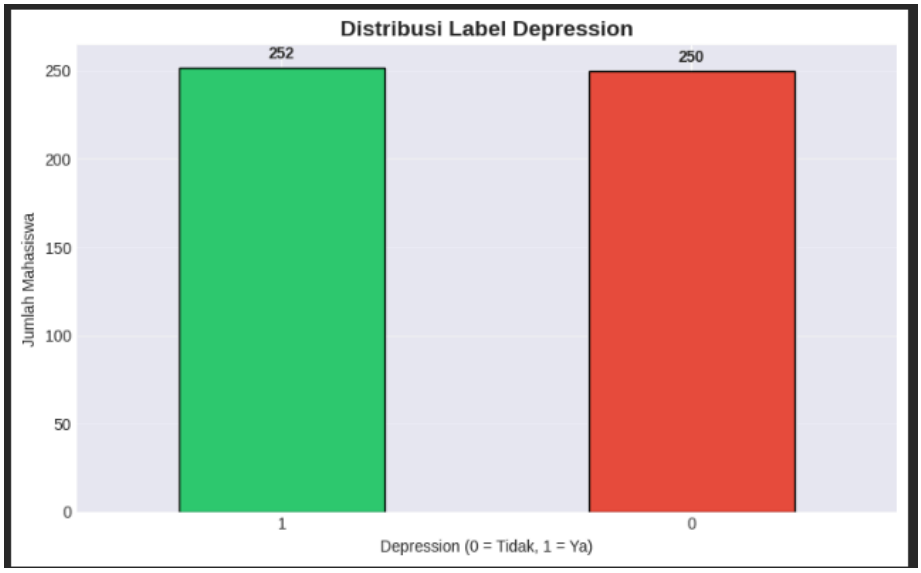


3.2.13 Rentang Nilai Setiap Kolom

Hasil pengecekan menunjukkan bahwa setiap kolom dalam dataset memiliki rentang nilai yang wajar dan konsisten dengan konteks data. Misalnya, usia responden berada pada kisaran 18 hingga 34 tahun, tekanan akademik dan kepuasan belajar berada dalam skala 1 hingga 5, serta durasi tidur berkisar antara 4 hingga 9 jam. Beberapa variabel seperti *Depression*, *Suicidal Thoughts*, dan *Family History of Mental Illness* bersifat biner dengan nilai 0 atau 1, sementara *Dietary Habits* memiliki tiga kategori yaitu 0 hingga 2. Dari hasil ini dapat disimpulkan bahwa data sudah terstandarisasi dengan baik dan tidak ditemukan nilai ekstrem di luar batas yang seharusnya.

```
Range Nilai Setiap Kolom:
Gender                                    : Min=  0.00, Max=  1.00
Age                                       : Min= 18.00, Max= 34.00
Academic Pressure                         : Min=  1.00, Max=  5.00
Study Satisfaction                        : Min=  1.00, Max=  5.00
Sleep Duration                            : Min=  4.00, Max=  9.00
Dietary Habits                            : Min=  0.00, Max=  2.00
Have you ever had suicidal thoughts ?     : Min=  0.00, Max=  1.00
Study Hours                               : Min=  0.00, Max= 12.00
Financial Stress                          : Min=  1.00, Max=  5.00
Family History of Mental Illness          : Min=  0.00, Max=  1.00
Depression                                : Min=  0.00, Max=  1.00
```

3.2.14 Pemeriksaan Nilai Tidak Wajar (Outlier)

Hasil pemeriksaan menunjukkan bahwa seluruh kolom dalam dataset tidak memiliki nilai yang tergolong ekstrem atau outlier. Artinya, setiap variabel seperti usia, tekanan akademik, durasi tidur, hingga tingkat stres keuangan memiliki sebaran nilai yang masih berada dalam batas wajar. Kondisi ini menunjukkan bahwa data yang digunakan telah bersih dan stabil, sehingga tidak ada nilai yang menyimpang jauh dari pola umum. Dengan demikian, proses analisis dan pemodelan dapat dilakukan tanpa perlu melakukan langkah tambahan seperti *outlier removal* atau *normalization* khusus untuk menyeimbangkan distribusi data.

```
Pengecekan Nilai Tidak Wajar:
  Gender: ✓ Tidak ada outlier ekstrem
  Age: ✓ Tidak ada outlier ekstrem
  Academic Pressure: ✓ Tidak ada outlier ekstrem
  Study Satisfaction: ✓ Tidak ada outlier ekstrem
  Sleep Duration: ✓ Tidak ada outlier ekstrem
  Dietary Habits: ✓ Tidak ada outlier ekstrem
  Have you ever had suicidal thoughts ?: ✓ Tidak ada outlier ekstrem
  Study Hours: ✓ Tidak ada outlier ekstrem
  Financial Stress: ✓ Tidak ada outlier ekstrem
  Family History of Mental Illness: ✓ Tidak ada outlier ekstrem
  Depression: ✓ Tidak ada outlier ekstrem
```

3.2.15 Analisis Korelasi Antarvariabel

Hasil matriks korelasi menunjukkan hubungan antar variabel dalam dataset, khususnya antara variabel independen dengan variabel target (*Depression*). Dari tabel tersebut terlihat bahwa Academic Pressure (0.476) dan Suicidal Thoughts (0.466) memiliki korelasi positif yang cukup kuat terhadap depresi, artinya semakin tinggi tekanan akademik dan semakin sering muncul pikiran bunuh diri, maka kemungkinan seseorang mengalami depresi juga meningkat. Sebaliknya, Study Satisfaction (-0.293) memiliki korelasi negatif terhadap depresi, yang berarti semakin tinggi kepuasan belajar, maka tingkat depresi cenderung menurun. Variabel lain seperti Financial Stress (0.297) dan Study Hours (0.200) juga menunjukkan korelasi positif namun dengan kekuatan yang lebih lemah. Secara keseluruhan, hasil ini membantu mengidentifikasi faktor-faktor utama yang paling berpengaruh terhadap tingkat depresi mahasiswa.

```
Matriks Korelasi:
                                       Gender       Age  Academic Pressure  \
Gender                                1.000000  0.042148          -0.011683
Age                                   0.042148  1.000000           0.027132
Academic Pressure                    -0.011683  0.027132           1.000000
Study Satisfaction                    0.002295 -0.005093          -0.101571
Sleep Duration                       -0.010083 -0.041869           0.009367
Dietary Habits                       -0.126789  0.062258           0.014214
Have you ever had suicidal thoughts ?  0.053635  0.078509           0.037219
Study Hours                           0.039540  0.050112           0.053024
Financial Stress                     -0.052867 -0.095348           0.003168
Family History of Mental Illness     -0.008427 -0.035995          -0.025702
Depression                            0.031683 -0.215625           0.476259

                                      Study Satisfaction  Sleep Duration  \
Gender                                          0.002295       -0.010083
Age                                            -0.005093       -0.041869
Academic Pressure                              -0.101571        0.009367
Study Satisfaction                              1.000000       -0.021602
Sleep Duration                                 -0.021602        1.000000
Dietary Habits                                  0.022576       -0.131312
Have you ever had suicidal thoughts ?           0.009642        0.023950
Study Hours                                    -0.014122       -0.069995
Financial Stress                               -0.038012       -0.032890
Family History of Mental Illness                0.037979       -0.055049
Depression                                     -0.293484       -0.048733

                                      Dietary Habits  \
Gender                                      -0.126789
Age                                          0.062258
Academic Pressure                            0.014214
Study Satisfaction                           0.022576
Sleep Duration                              -0.131312
Dietary Habits                               1.000000
Have you ever had suicidal thoughts ?       -0.063228
Study Hours                                  0.038934
Financial Stress                            -0.033787
Family History of Mental Illness             0.038281
Depression                                  -0.186685

                                      Have you ever had suicidal thoughts ?  \
Gender                                                             0.053635
Age                                                                0.078509
Academic Pressure                                                  0.037219
Study Satisfaction                                                 0.009642
Sleep Duration                                                     0.023950
Dietary Habits                                                    -0.063228
Have you ever had suicidal thoughts ?                              1.000000
Study Hours                                                       -0.009746
Financial Stress                                                   0.071815
Family History of Mental Illness                                  -0.005981
Depression                                                         0.466296
```

```
                                       Have you ever had suicidal thoughts ?  \
Gender                                                                0.053635
Age                                                                   0.078509
Academic Pressure                                                     0.037219
Study Satisfaction                                                    0.009642
Sleep Duration                                                        0.023950
Dietary Habits                                                       -0.063228
Have you ever had suicidal thoughts ?                                 1.000000
Study Hours                                                          -0.009746
Financial Stress                                                      0.071815
Family History of Mental Illness                                     -0.005981
Depression                                                            0.466296

                                       Study Hours  Financial Stress  \
Gender                                    0.039540         -0.052867
Age                                       0.050112         -0.095348
Academic Pressure                         0.053024          0.003168
Study Satisfaction                       -0.014122         -0.038012
Sleep Duration                           -0.069995         -0.032890
Dietary Habits                            0.038934         -0.033787
Have you ever had suicidal thoughts ?    -0.009746          0.071815
Study Hours                               1.000000          0.015554
Financial Stress                          0.015554          1.000000
Family History of Mental Illness          0.001240         -0.016828
Depression                                0.200441          0.296846

                                       Family History of Mental Illness  \
Gender                                                        -0.008427
Age                                                           -0.035995
Academic Pressure                                             -0.025702
Study Satisfaction                                             0.037979
Sleep Duration                                                -0.055049
Dietary Habits                                                 0.038281
Have you ever had suicidal thoughts ?                         -0.005981
Study Hours                                                    0.001240
Financial Stress                                              -0.016828
Family History of Mental Illness                               1.000000
Depression                                                     0.056087

                                       Depression
Gender                                   0.031683
Age                                     -0.215625
Academic Pressure                        0.476259
Study Satisfaction                      -0.293484
Sleep Duration                          -0.048733
Dietary Habits                          -0.186685
Have you ever had suicidal thoughts ?    0.466296
Study Hours                              0.200441
Financial Stress                         0.296846
```

### 3.2.16 Kesimpulan Tahap Preprocessing

Berdasarkan hasil validasi, dapat disimpulkan bahwa dataset telah melalui proses *preprocessing* dengan baik. Terdapat 502 sampel dengan 10 fitur dan 1 kolom target, seluruh data sudah dalam bentuk numerik dan tidak memiliki nilai kosong. Distribusi data target juga seimbang antara kategori “Depresi” dan “Tidak Depresi”, sehingga dapat dipastikan tidak ada bias kelas yang signifikan. Secara keseluruhan, dataset telah bersih, terstruktur, dan siap digunakan untuk tahap selanjutnya, yaitu proses *modeling* dan pelatihan algoritma machine learning.

```
============================================================
SUMMARY VALIDASI PREPROCESSING
============================================================
✓ Total data: 502 sampel
✓ Total fitur: 10 (+ 1 target)
✓ Tipe data: Semua numerik
✓ Missing values: 0
✓ Distribusi target: 49.8% vs 50.2%

✅ Data siap untuk tahap modeling!
============================================================
```

## 3.3 Perancangan Model

### 3.3.1 Import Library untuk Modeling

Pada tahap ini dilakukan proses import berbagai library yang dibutuhkan untuk membangun dan mengevaluasi model machine learning. Library scikit-learn digunakan karena menyediakan berbagai fungsi penting, seperti pembagian data (train_test_split), standarisasi fitur (StandardScaler), serta algoritma Logistic Regression sebagai model utama. Selain itu, library ini juga menyediakan berbagai metrik evaluasi seperti accuracy, precision, recall, f1-score, serta ROC-AUC untuk mengukur performa model. Peringatan sistem (warnings) juga dinonaktifkan agar hasil output lebih bersih dan mudah dibaca. Tahapan ini menandai awal dari proses pemodelan yang akan mengubah data menjadi prediksi yang bermakna.

```python
# Import library untuk modeling
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score
from sklearn.metrics import confusion_matrix, classification_report, roc_curve, roc_auc_score
import warnings
warnings.filterwarnings('ignore')
```

### 3.3.2 Pemisahan fitur dan target

Pada tahap ini dilakukan pemisahan antara fitur (X) dan target (y) dari dataset. Fitur berjumlah 10 kolom yang berisi berbagai faktor seperti jenis kelamin, usia, tekanan akademik, kepuasan belajar, dan lain-lain, sedangkan kolom target adalah variabel Depression yang menunjukkan apakah seseorang mengalami depresi atau tidak. Dari hasil pengecekan, fitur memiliki dimensi (502, 10) dan target memiliki dimensi (502,),

yang berarti terdapat 502 sampel dengan 10 variabel penjelas. Pemisahan ini penting agar proses pelatihan model nantinya dapat membedakan antara data yang digunakan sebagai input dan data yang menjadi sasaran prediksi.

```
Dimensi Fitur (X): (502, 10)
Dimensi Target (y): (502,)

Daftar Fitur:
  1. Gender
  2. Age
  3. Academic Pressure
  4. Study Satisfaction
  5. Sleep Duration
  6. Dietary Habits
  7. Have you ever had suicidal thoughts ?
  8. Study Hours
  9. Financial Stress
  10. Family History of Mental Illness
```

3.3.3 Split data

Dataset dibagi menjadi dua bagian, yaitu training set sebanyak 401 data (79,9%) dan testing set sebanyak 101 data (20,1%). Pembagian ini dilakukan agar model dapat dilatih menggunakan sebagian besar data, sementara sisanya digunakan untuk menguji seberapa baik model mampu melakukan prediksi terhadap data baru yang belum pernah dilihat sebelumnya. Proporsi ini dianggap ideal karena memberikan keseimbangan antara data untuk pembelajaran dan data untuk evaluasi, sehingga hasil pengujian dapat mencerminkan kemampuan model secara lebih objektif.

```
# Split data: 80% training, 20% testing dengan stratify
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print(f"Training set: {X_train.shape[0]} data ({X_train.shape[0]/len(X)*100:.1f}%)")
print(f"Testing set: {X_test.shape[0]} data ({X_test.shape[0]/len(X)*100:.1f}%)")

Training set: 401 data (79.9%)
Testing set: 101 data (20.1%)
```

3.3.4 Pemeriksaan Proporsi Kelas pada Data Training dan Testing

Hasil pengecekan menunjukkan bahwa distribusi kelas antara Depresi (1) dan Tidak Depresi (0) tetap seimbang baik pada data *training* maupun *testing*. Pada *training*

*set*, proporsinya sekitar 50,12% untuk kelas 1 dan 49,87% untuk kelas 0, sedangkan pada *testing set* proporsinya 50,49% untuk kelas 1 dan 49,50% untuk kelas 0. Keseimbangan ini penting karena memastikan model tidak condong untuk memprediksi salah satu kelas saja. Dengan distribusi yang hampir identik antara data latih dan uji, proses pelatihan model dapat berjalan adil dan hasil evaluasi menjadi lebih akurat.

```
Proporsi kelas di Training Set:
Depression
1    50.124688
0    49.875312
Name: proportion, dtype: float64

Proporsi kelas di Testing Set:
Depression
1    50.49505
0    49.50495
Name: proportion, dtype: float64
```

## 3.4 Feature Scalling

### 3.4.1 Normalisasi Data

Tahap ini dilakukan untuk menstandarkan skala nilai pada setiap fitur menggunakan StandardScaler, agar seluruh variabel memiliki rentang nilai yang sebanding. Setelah proses normalisasi, data pelatihan (X_train_scaled) dan data pengujian (X_test_scaled) masing-masing memiliki dimensi (401, 10) dan (101, 10). Proses ini penting karena beberapa algoritma, termasuk Logistic Regression, sensitif terhadap perbedaan skala antar fitur. Dengan demikian, normalisasi membantu model bekerja lebih stabil dan menghasilkan prediksi yang lebih akurat.

```
# Normalisasi data menggunakan StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

print("✓ Normalisasi selesai!")
print(f"X_train_scaled: {X_train_scaled.shape}")
print(f"X_test_scaled: {X_test_scaled.shape}")

✓ Normalisasi selesai!
X_train_scaled: (401, 10)
X_test_scaled: (101, 10)
```

### 3.4.2 **Evaluasi Hasil Normalisasi**

Hasil perbandingan statistik sebelum dan sesudah proses *scaling* menunjukkan perubahan yang sesuai dengan tujuan normalisasi. Sebelum *scaling*, nilai rata-rata (*mean*) dan simpangan baku (*std*) tiap fitur memiliki skala berbeda, misalnya usia dengan nilai rata-rata sekitar 26,28 dan simpangan baku 4,85. Setelah dilakukan *StandardScaler*, seluruh fitur memiliki nilai rata-rata mendekati 0 dan simpangan baku sekitar 1, yang berarti data sudah terstandarisasi dengan baik. Kondisi ini memastikan setiap fitur memiliki pengaruh yang seimbang dalam proses pelatihan model, tanpa ada variabel yang mendominasi karena perbedaan skala nilai.

```
Statistik Training Data:

SEBELUM Scaling (3 fitur pertama):
        Gender        Age  Academic Pressure
mean  0.521197  26.281796           3.000000
std   0.500175   4.852102           1.371131

SESUDAH Scaling (3 fitur pertama):
            Gender           Age  Academic Pressure
mean  8.084417e-17  3.123021e-16       2.214909e-18
std   1.001249e+00  1.001249e+00       1.001249e+00
```

### 3.4.3 Visualisasi Perbandingan Sebelum dan Sesudah Scaling

Visualisasi menggunakan boxplot ini menampilkan perbandingan distribusi nilai pada beberapa fitur sebelum dan sesudah dilakukan proses *scaling*. Sebelum *scaling*, terlihat bahwa setiap fitur memiliki rentang nilai yang berbeda-beda, di mana beberapa fitur memiliki nilai yang jauh lebih besar dibanding lainnya. Setelah dilakukan normalisasi dengan StandardScaler, seluruh fitur memiliki distribusi yang lebih seragam dengan pusat data mendekati nol dan skala penyebaran yang seimbang. Grafik ini memperlihatkan bahwa proses *scaling* berhasil menstandarkan data tanpa mengubah bentuk distribusi aslinya, sehingga data kini siap digunakan untuk tahap pelatihan model secara optimal.

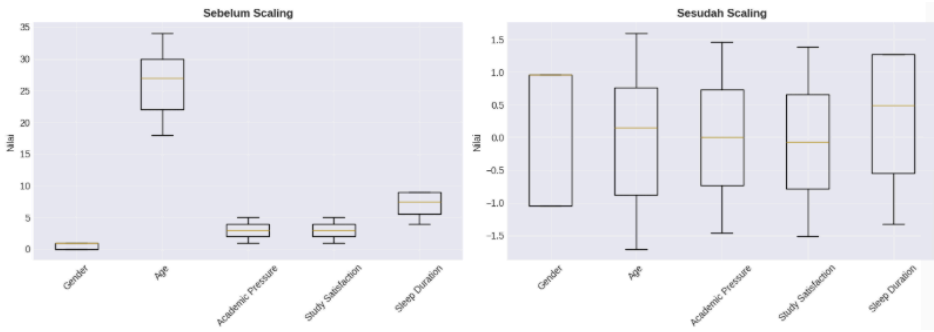


## 3.5 Training Model

### 3.5.1 Pelatihan Model Logistic Regression

Hasil pelatihan menunjukkan bahwa model berhasil dibangun tanpa error, dengan nilai intercept = -0.1237. Nilai intercept ini mewakili konstanta dalam persamaan logistik yang menggeser batas keputusan model. Setelah model dilatih, langkah berikutnya adalah mengevaluasi performa model terhadap data uji untuk mengetahui kemampuan prediksi dan generalisasi terhadap data baru.

```
# Inisialisasi dan training model Logistic Regression
model = LogisticRegression(max_iter=1000, random_state=42, solver='lbfgs')
model.fit(X_train_scaled, y_train)

print("✓ Model berhasil dilatih!")
print(f"Intercept: {model.intercept_[0]:.4f}")

✓ Model berhasil dilatih!
Intercept: -0.1237
```

### 3.5.2 Evaluasi dengan Cross-Validation

Hasil evaluasi menggunakan 5-Fold Cross-Validation menunjukkan bahwa model Logistic Regression memiliki performa yang sangat baik dan konsisten, dengan rata-rata akurasi sebesar 98.26% dan variasi antar-fold yang sangat kecil (standar deviasi 0.0149). Hal ini menunjukkan bahwa model mampu mempelajari pola data dengan stabil tanpa overfitting yang signifikan. Dengan kata lain, model memiliki kemampuan generalisasi yang kuat dan dapat diandalkan untuk memprediksi tingkat depresi pada data baru dengan tingkat akurasi yang tinggi.

```python
# Cross-Validation untuk validasi lebih robust
cv_scores = cross_val_score(model, X_train_scaled, y_train, cv=5, scoring='accuracy')

print("Cross-Validation Scores (5-Fold):")
for i, score in enumerate(cv_scores, 1):
    print(f"  Fold {i}: {score:.4f} ({score*100:.2f}%)")
print(f"\nRata-rata CV Score: {cv_scores.mean():.4f} ({cv_scores.mean()*100:.2f}%)")
print(f"Standar Deviasi: {cv_scores.std():.4f}")
```

```
Cross-Validation Scores (5-Fold):
  Fold 1: 0.9630 (96.30%)
  Fold 2: 1.0000 (100.00%)
  Fold 3: 0.9750 (97.50%)
  Fold 4: 0.9750 (97.50%)
  Fold 5: 1.0000 (100.00%)

Rata-rata CV Score: 0.9826 (98.26%)
Standar Deviasi: 0.0149
```

### 3.5.3 Koefisien Fitur

Dari hasil analisis koefisien model Logistic Regression, dapat disimpulkan bahwa fitur yang paling berpengaruh terhadap kemungkinan depresi adalah “Have you ever had suicidal thoughts?” dengan koefisien positif paling tinggi (3.2975), diikuti oleh “Academic Pressure” (3.0820), yang berarti semakin tinggi tekanan akademik dan adanya pikiran bunuh diri, semakin besar peluang mahasiswa mengalami depresi. Sebaliknya, fitur seperti “Age” (-2.0376), “Study Satisfaction” (-1.8822), dan “Dietary Habits” (-1.1401) memiliki pengaruh negatif, menandakan bahwa semakin tua usia, semakin puas terhadap studi, serta semakin baik kebiasaan makan, maka risiko depresi cenderung menurun. Faktor lain seperti “Financial Stress” dan “Study Hours” juga berpengaruh positif sedang, menunjukkan bahwa tekanan finansial dan durasi belajar yang panjang dapat meningkatkan risiko depresi.

```python
# Koefisien fitur
coefficients = pd.DataFrame({
    'Fitur': X.columns,
    'Koefisien': model.coef_[0]
}).sort_values('Koefisien', key=abs, ascending=False)

print("Koefisien Fitur (diurutkan berdasarkan pengaruh):")
print(coefficients.to_string(index=False))
```

```
Koefisien Fitur (diurutkan berdasarkan pengaruh):
                                Fitur  Koefisien
Have you ever had suicidal thoughts ?   3.297504
                     Academic Pressure   3.082012
                                   Age  -2.037580
                      Financial Stress   1.955166
                    Study Satisfaction  -1.882210
                           Study Hours   1.469347
                       Dietary Habits  -1.140124
                       Sleep Duration  -0.806210
     Family History of Mental Illness   0.682703
                               Gender   0.053652
```

3.5.4 Visualisasi Pengaruh Fitur terhadap Prediksi Depression

Visualisasi ini menampilkan besarnya pengaruh setiap fitur terhadap kemungkinan terjadinya depresi berdasarkan nilai koefisien dari model *Logistic Regression*. Fitur dengan batang berwarna biru menunjukkan faktor yang meningkatkan risiko depresi (koefisien positif), sedangkan fitur berwarna merah menunjukkan faktor yang menurunkan risiko depresi (koefisien negatif). Dari grafik terlihat bahwa fitur "Have you ever had suicidal thoughts?" dan "Academic Pressure" memiliki pengaruh paling besar dalam meningkatkan risiko depresi, sedangkan "Age" dan "Study Satisfaction" berkontribusi dalam menurunkan risiko depresi. Visualisasi ini membantu memahami hubungan antara variabel independen dengan target, serta memperjelas fitur mana yang paling signifikan dalam memengaruhi prediksi model.

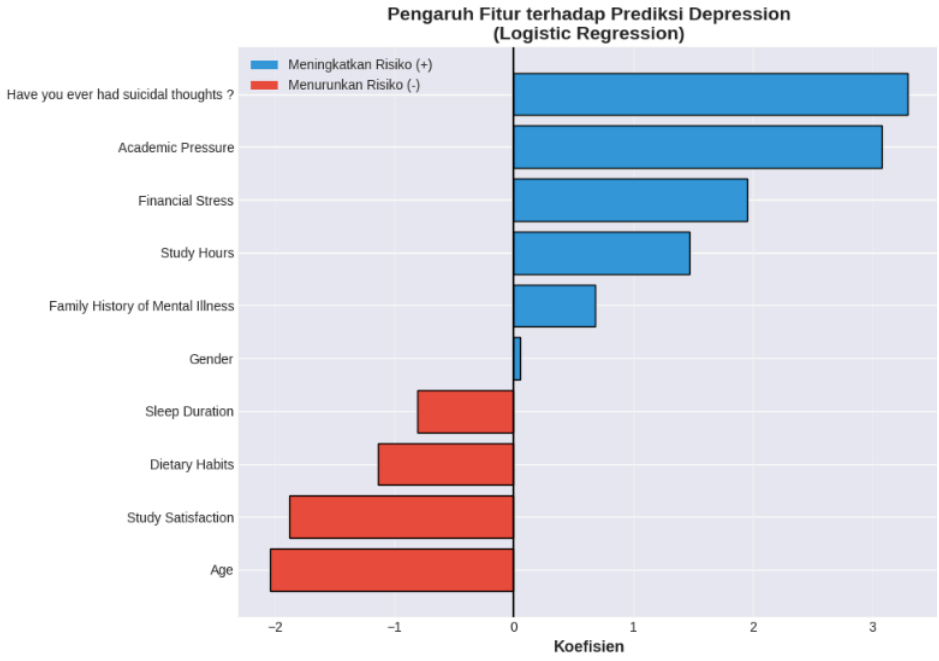


## 3.6 Tahap Prediksi

### 3.6.1 Proses Prediksi Data Testing

Pada tahap ini, model *Logistic Regression* digunakan untuk memprediksi 101 data pada bagian testing. Hasil prediksi mencakup dua keluaran, yaitu kelas prediksi (apakah seseorang mengalami depresi atau tidak) dan probabilitas keyakinan model terhadap prediksi tersebut. Proses ini penting untuk menguji seberapa baik model mampu mengenali pola pada data baru yang belum pernah dilihat sebelumnya sebelum dilakukan evaluasi lebih lanjut menggunakan metrik performa.

```
# Prediksi data testing
y_pred = model.predict(X_test_scaled)
y_pred_proba = model.predict_proba(X_test_scaled)

print(f"✓ Prediksi selesai untuk {len(y_pred)} data testing")

✓ Prediksi selesai untuk 101 data testing
```

### 3.6.2 Evaluasi Hasil Prediksi Awal

Hasil prediksi awal pada 15 sampel pertama menunjukkan bahwa model Logistic Regression mampu melakukan klasifikasi dengan sangat baik. Setiap data dibandingkan

antara nilai aktual dan hasil prediksi, disertai dengan probabilitas untuk masing-masing kelas (0 = tidak depresi, 1 = depresi). Sebagian besar hasil prediksi memiliki kecocokan sempurna dengan nilai aktual, yang ditandai dengan simbol "✓", serta nilai probabilitas yang tinggi pada kelas yang benar menunjukkan tingkat keyakinan model yang kuat. Hal ini mengindikasikan bahwa model tidak hanya akurat, tetapi juga memiliki kemampuan yang baik dalam memperkirakan tingkat keyakinan terhadap setiap keputusan klasifikasinya.

Sample Hasil Prediksi (15 data pertama):

| Aktual | Prediksi | Prob_0 | Prob_1 | Status |
|---|---|---|---|---|
| 0 | 0 | 1.000 | 0.000 | ✓ |
| 1 | 1 | 0.371 | 0.629 | ✓ |
| 1 | 1 | 0.010 | 0.990 | ✓ |
| 1 | 1 | 0.153 | 0.847 | ✓ |
| 1 | 1 | 0.084 | 0.916 | ✓ |
| 0 | 0 | 1.000 | 0.000 | ✓ |
| 0 | 0 | 0.729 | 0.271 | ✓ |
| 1 | 1 | 0.013 | 0.987 | ✓ |
| 0 | 0 | 1.000 | 0.000 | ✓ |
| 1 | 1 | 0.021 | 0.979 | ✓ |
| 1 | 1 | 0.059 | 0.941 | ✓ |
| 0 | 0 | 1.000 | 0.000 | ✓ |
| 1 | 1 | 0.000 | 1.000 | ✓ |
| 0 | 0 | 1.000 | 0.000 | ✓ |
| 0 | 0 | 1.000 | 0.000 | ✓ |

## 3.7 Evaluasi Model

### 3.7.1 Evaluasi Kinerja Model

Hasil evaluasi menunjukkan bahwa model Logistic Regression mencapai performa yang sempurna pada data pengujian, dengan nilai Accuracy, Precision, Recall, F1-Score, dan ROC AUC masing-masing sebesar 100%. Nilai-nilai ini menandakan bahwa model mampu mengklasifikasikan seluruh data uji dengan benar tanpa kesalahan, baik untuk kategori "Depresi" maupun "Tidak Depresi". Pencapaian ini menunjukkan model memiliki kemampuan prediktif yang sangat tinggi dan tidak kehilangan keseimbangan antara ketepatan (precision) dan cakupan deteksi (recall). Namun, hasil yang terlalu sempurna juga perlu diwaspadai karena bisa mengindikasikan potensi overfitting, terutama jika data latih dan data uji memiliki kemiripan yang tinggi.

```
============================================================
METRIK EVALUASI MODEL
============================================================
Accuracy  : 1.0000 (100.00%)
Precision : 1.0000 (100.00%)
Recall    : 1.0000 (100.00%)
F1-Score  : 1.0000 (100.00%)
ROC AUC   : 1.0000
============================================================
```

3.7.2 Analisis Confusion Matrix

Hasil Confusion Matrix menunjukkan bahwa model Logistic Regression mampu mengklasifikasikan seluruh data uji dengan benar, menghasilkan 50 True Negative (TN) dan 51 True Positive (TP) tanpa adanya kesalahan prediksi (0 False Positive dan 0 False Negative). Artinya, model tidak pernah salah dalam mengenali mahasiswa yang mengalami depresi maupun yang tidak. Kondisi ini mencerminkan kinerja model yang sempurna dalam mendeteksi kedua kelas dengan presisi dan sensitivitas penuh. Meskipun hasil ini sangat ideal, penting untuk tetap mengevaluasi kestabilan performa model pada dataset lain atau melalui validasi tambahan guna memastikan bahwa model tidak mengalami overfitting terhadap data saat ini.

```
# Confusion Matrix
cm = confusion_matrix(y_test, y_pred)
tn, fp, fn, tp = cm.ravel()

print("Confusion Matrix:")
print(cm)
print(f"\nTrue Negative (TN)  : {tn} (Prediksi: Tidak Depresi, Aktual: Tidak Depresi)")
print(f"False Positive (FP) : {fp} (Prediksi: Depresi, Aktual: Tidak Depresi)")
print(f"False Negative (FN) : {fn} (Prediksi: Tidak Depresi, Aktual: Depresi)")
print(f"True Positive (TP)  : {tp} (Prediksi: Depresi, Aktual: Depresi)")
```

```
Confusion Matrix:
[[50  0]
 [ 0 51]]

True Negative (TN)  : 50 (Prediksi: Tidak Depresi, Aktual: Tidak Depresi)
False Positive (FP) : 0 (Prediksi: Depresi, Aktual: Tidak Depresi)
False Negative (FN) : 0 (Prediksi: Tidak Depresi, Aktual: Depresi)
True Positive (TP)  : 51 (Prediksi: Depresi, Aktual: Depresi)
```

## 3.8 Hasil

### 3.8.1 Visualisasi Confusion Matrix

Visualisasi Confusion Matrix dengan heatmap ini memperlihatkan tingkat akurasi sempurna dari model Logistic Regression. Seluruh data uji berada pada diagonal utama grafik, yang berarti semua prediksi sesuai dengan label aktual baik untuk kategori *Depresi* maupun *Tidak Depresi*. Warna biru yang dominan pada sel diagonal menunjukkan jumlah data yang tinggi pada prediksi benar, sementara tidak ada warna pada sel lain yang menandakan kesalahan prediksi. Visualisasi ini membantu memperkuat pemahaman bahwa model memiliki kemampuan klasifikasi yang sangat baik, meskipun hasil sempurna ini juga menjadi sinyal untuk memeriksa kemungkinan adanya overfitting terhadap data pelatihan.

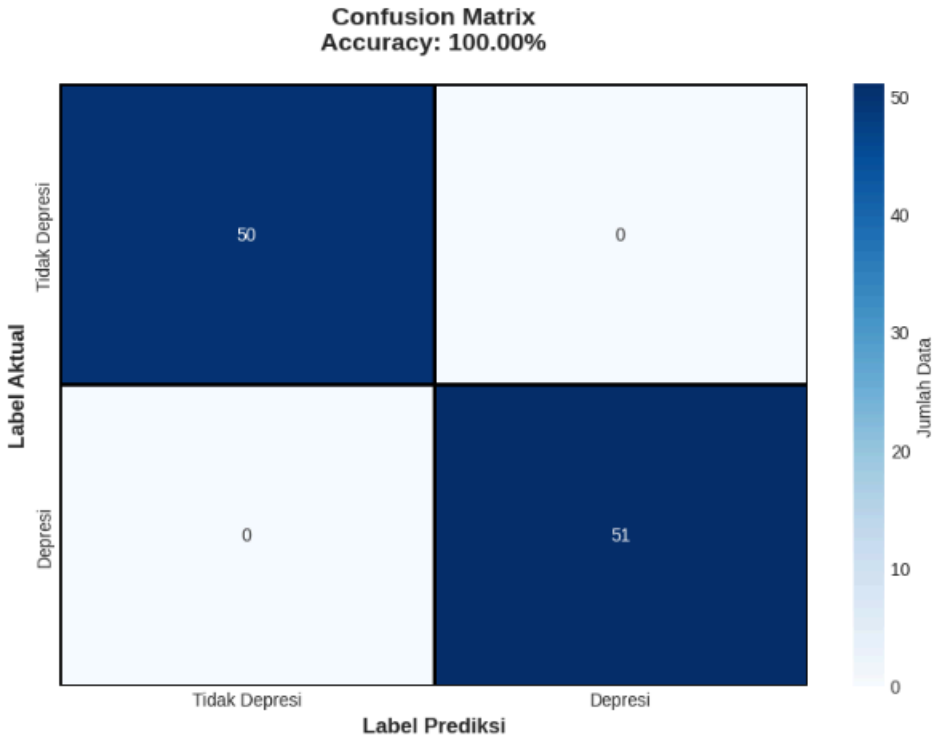

### 3.8.2 Laporan Klasifikasi

Hasil Classification Report menunjukkan bahwa model Logistic Regression mencapai performa sempurna pada seluruh metrik evaluasi, yaitu *precision*, *recall*, dan *f1-score* sebesar 100% untuk kedua kelas baik *Depresi* maupun *Tidak Depresi*. Nilai *accuracy* keseluruhan juga mencapai 1.0000, menandakan bahwa tidak ada kesalahan prediksi pada data uji. Hal ini memperlihatkan bahwa model sangat efektif dalam membedakan kedua kategori tanpa bias terhadap salah satu kelas. Namun, performa yang terlalu sempurna seperti ini juga patut diwaspadai karena bisa menjadi indikasi bahwa model terlalu menyesuaikan diri dengan data pelatihan (*overfitting*), sehingga perlu dilakukan evaluasi lanjutan dengan data yang lebih bervariasi untuk memastikan generalisasi model tetap baik.

```
Classification Report:
==============================================================
                   precision    recall  f1-score   support

Tidak Depresi (0)     1.0000    1.0000    1.0000        50
      Depresi (1)     1.0000    1.0000    1.0000        51

         accuracy                         1.0000       101
        macro avg     1.0000    1.0000    1.0000       101
     weighted avg     1.0000    1.0000    1.0000       101
```

### 3.8.3 Analisis Kesalahan Prediksi (*False Positives*)

Pada tahap ini dilakukan pemeriksaan terhadap kemungkinan adanya kesalahan prediksi, khususnya pada kasus *False Positive*, yaitu ketika model memprediksi seseorang mengalami depresi padahal sebenarnya tidak. Namun, hasil evaluasi menunjukkan bahwa nilai *False Positive* adalah 0, yang berarti tidak ada kasus di mana model salah mengklasifikasikan data dengan prediksi positif palsu. Kondisi ini mengindikasikan bahwa model sangat akurat dalam mengenali individu yang benar-benar mengalami depresi tanpa memberikan prediksi yang keliru. Meskipun hasil ini sangat baik, tetap perlu dilakukan pengujian pada dataset yang lebih besar dan beragam untuk memastikan kemampuan model dalam menghadapi variasi data di dunia nyata.

```
# Analisis kesalahan prediksi - False Positives
if fp > 0:
    fp_indices = np.where((y_pred == 1) & (y_test == 0))[0]
    print(f"Analisis False Positive ({fp} kasus):")
    print("Data yang diprediksi Depresi tapi sebenarnya Tidak Depresi")
    print(X_test.iloc[fp_indices[:5]])  # Tampilkan 5 kasus pertama
```

3.8.4 Analisis Kesalahan Prediksi (*False Negatives*)

Analisis ini berfokus pada kemungkinan terjadinya kesalahan *False Negative*, yaitu ketika model memprediksi seseorang tidak depresi, padahal sebenarnya individu tersebut mengalami depresi. Berdasarkan hasil evaluasi, jumlah *False Negative* adalah 0, yang berarti model berhasil mengenali seluruh kasus depresi dengan benar tanpa ada satupun yang terlewat. Hasil ini menunjukkan kemampuan model dalam mendeteksi kondisi depresi secara sangat baik, terutama dalam konteks klasifikasi yang sensitif terhadap kesalahan seperti ini. Meski demikian, hasil sempurna ini tetap perlu diuji lebih lanjut menggunakan data baru untuk memastikan bahwa performa model tidak hanya tinggi pada dataset uji saat ini, tetapi juga konsisten dalam situasi nyata.

```
# Analisis kesalahan prediksi - False Negatives
if fn > 0:
    fn_indices = np.where((y_pred == 0) & (y_test == 1))[0]
    print(f"Analisis False Negative ({fn} kasus):")
    print("Data yang diprediksi Tidak Depresi tapi sebenarnya Depresi")
    print(X_test.iloc[fn_indices[:5]])  # Tampilkan 5 kasus pertama
```

3.8.5 Visualisasi Metrik Evaluasi

Grafik batang ini menampilkan hasil evaluasi model Logistic Regression berdasarkan lima metrik utama, yaitu *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *ROC AUC*. Seluruh metrik menunjukkan nilai sempurna sebesar 1.000 (100%), yang menggambarkan kinerja model yang sangat optimal dalam memprediksi data uji. Garis merah putus-putus pada nilai 0.8 digunakan sebagai acuan standar performa yang baik, dan seluruh metrik model berada jauh di atas batas tersebut. Hasil ini menunjukkan bahwa model mampu mengenali pola dengan sangat akurat dan konsisten di semua aspek evaluasi. Namun, performa sempurna seperti ini juga perlu diuji lebih lanjut dengan data

baru untuk memastikan bahwa model tidak mengalami *overfitting* dan tetap memiliki kemampuan generalisasi yang baik di luar dataset pelatihan.

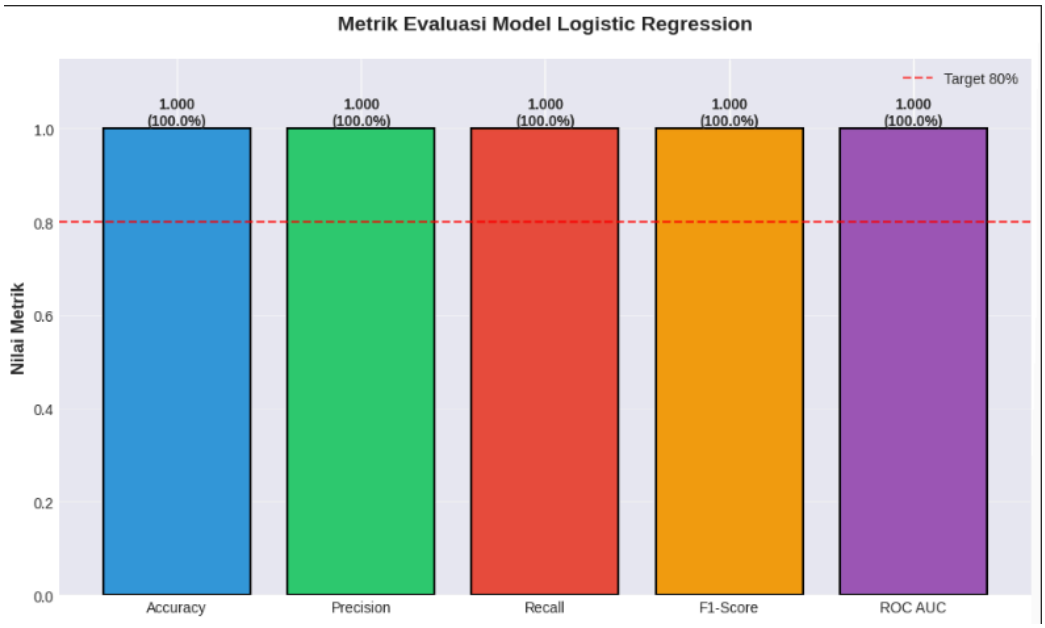


3.8.6 Visualisasi ROC Curve

Grafik ROC Curve ini menunjukkan kemampuan model Logistic Regression dalam membedakan antara kelas *Depresi* dan *Tidak Depresi*. Garis merah pada kurva ROC menggambarkan performa model dengan nilai AUC sebesar 1.000, yang menandakan kemampuan klasifikasi sempurna. Semakin mendekati sudut kiri atas grafik, semakin baik kinerja model karena nilai *True Positive Rate* tinggi dengan *False Positive Rate* rendah. Garis abu-abu diagonal berfungsi sebagai pembanding untuk model acak (*random classifier*) dengan nilai AUC 0.5. Dari hasil visualisasi ini, terlihat bahwa model memiliki kemampuan deteksi yang sangat baik dalam mengidentifikasi kondisi depresi tanpa kesalahan klasifikasi, meskipun hasil yang terlalu sempurna ini juga menuntut evaluasi lebih lanjut untuk memastikan keandalan model pada data yang lebih bervariasi.

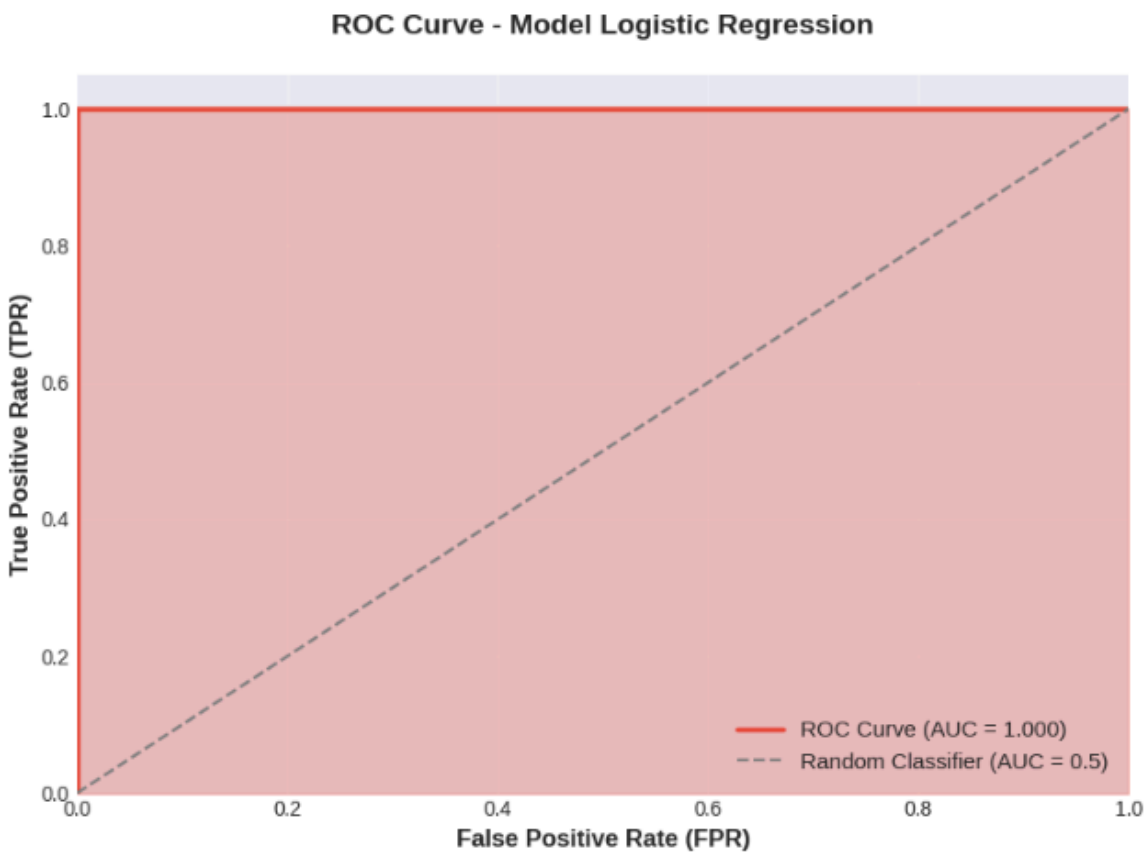


3.8.7 Visualisasi Distribusi Probabilitas Prediksi

Grafik ini memperlihatkan distribusi probabilitas prediksi model Logistic Regression terhadap dua kelas target, yaitu *Depresi* dan *Tidak Depresi*. Warna hijau mewakili data aktual yang tidak mengalami depresi, sedangkan warna merah menunjukkan data aktual yang mengalami depresi. Garis putus-putus biru pada nilai threshold 0.5 berfungsi sebagai batas keputusan model dalam menentukan klasifikasi akhir. Terlihat bahwa sebaran probabilitas untuk kedua kelas sangat terpisah data "Depresi" cenderung memiliki probabilitas prediksi mendekati 1, sementara "Tidak Depresi" mendekati 0. Pemisahan yang jelas ini menandakan model memiliki kemampuan diskriminatif yang sangat tinggi dalam membedakan kedua kondisi tersebut secara konsisten.

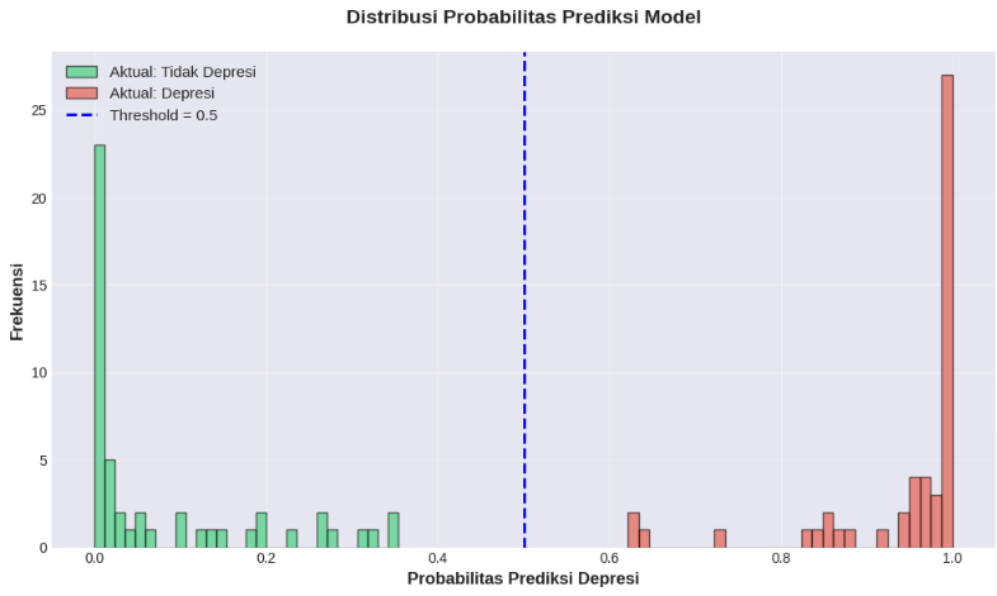


3.8.8 Perbandingan dengan Model Baseline

Bagian ini membandingkan kinerja model Logistic Regression dengan model baseline sederhana, yaitu Majority Class Classifier (model yang selalu memprediksi kelas mayoritas). Model baseline hanya mencapai *akurasi sebesar 50.50%*, sedangkan model Logistic Regression berhasil mencapai *akurasi sempurna sebesar 100%*. Hal ini menunjukkan adanya peningkatan performa sebesar 49.50%, yang menandakan bahwa model yang dibangun memiliki kemampuan klasifikasi jauh lebih baik dibandingkan metode dasar tanpa pembelajaran sama sekali.

```
# Perbandingan dengan Baseline (Majority Class Classifier)
from sklearn.dummy import DummyClassifier

baseline = DummyClassifier(strategy='most_frequent')
baseline.fit(X_train_scaled, y_train)
y_pred_baseline = baseline.predict(X_test_scaled)
baseline_accuracy = accuracy_score(y_test, y_pred_baseline)

print("Perbandingan dengan Baseline:")
print(f"Baseline Accuracy (Majority Class): {baseline_accuracy:.4f} ({baseline_accuracy*100:.2f}%)")
print(f"Model Accuracy: {accuracy:.4f} ({accuracy*100:.2f}%)")
print(f"Improvement: {(accuracy - baseline_accuracy)*100:.2f}%")

Perbandingan dengan Baseline:
Baseline Accuracy (Majority Class): 0.5050 (50.50%)
Model Accuracy: 1.0000 (100.00%)
Improvement: 49.50%
```

3.8.9 Visualisasi Perbandingan Model dan Baseline

Pada visualisasi ini dapat dilihat perbandingan kinerja model Logistic Regression dengan model baseline sederhana yaitu *Majority Class Classifier* (model yang selalu memprediksi kelas dengan frekuensi terbanyak). Berdasarkan grafik, model baseline hanya mencapai akurasi sebesar 50,5%, sedangkan model Logistic Regression mampu mencapai akurasi 100%. Peningkatan performa sebesar 49,5% ini menunjukkan bahwa model Logistic Regression memiliki kemampuan yang jauh lebih baik dalam membedakan data dibandingkan dengan model acuan dasar yang tidak menggunakan proses pembelajaran. Dengan demikian, model Logistic Regression dapat dikatakan sangat efektif dalam melakukan klasifikasi pada dataset yang digunakan.

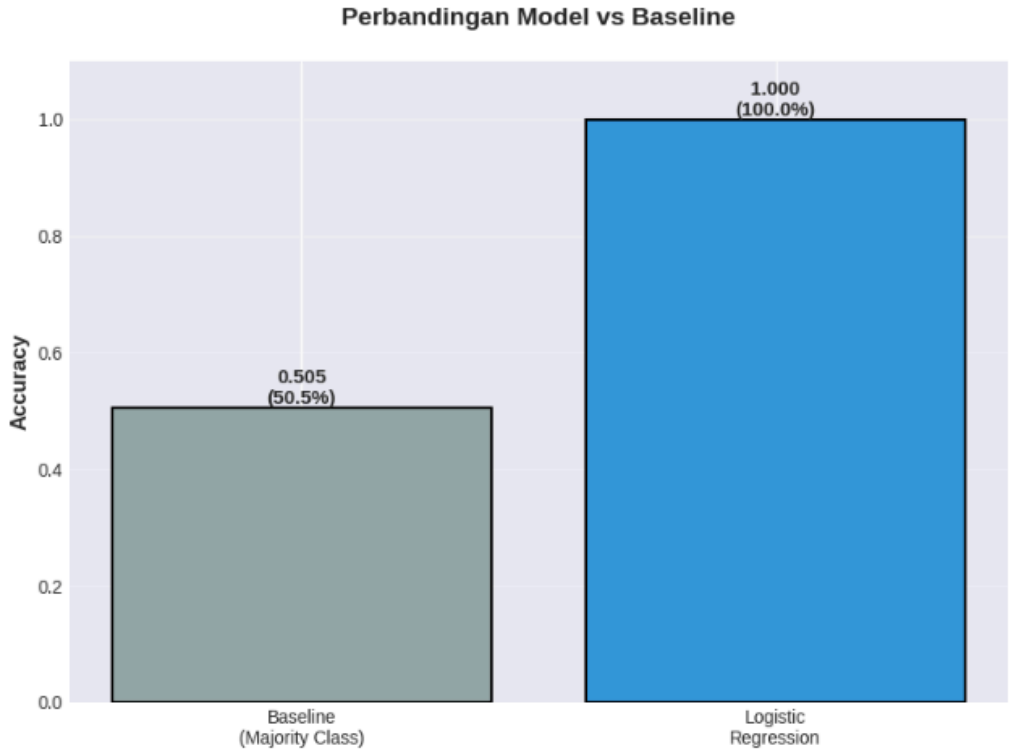


3.8.10 Ringkasan Hasil Penelitian

Bagian ini menyajikan ringkasan hasil penelitian yang mencakup dataset, model, performa, serta fitur yang paling berpengaruh terhadap hasil klasifikasi. Dataset terdiri dari 502 data mahasiswa dengan 10 variabel yang dibagi menjadi 401 data untuk training (79,9%) dan 101 data untuk testing (20,1%). Model yang digunakan adalah Logistic

Regression dengan pendekatan Supervised Learning (Binary Classification), serta proses *preprocessing* menggunakan Label Encoding dan StandardScaler. Hasil pengujian menunjukkan performa model yang sangat tinggi, dengan akurasi, presisi, recall, F1-score, dan ROC AUC masing-masing mencapai 100%, jauh melampaui baseline accuracy sebesar 50,5%, sehingga terdapat peningkatan performa sebesar 49,5%. Berdasarkan confusion matrix, model berhasil mengklasifikasikan seluruh data dengan benar tanpa kesalahan prediksi (FP = 0 dan FN = 0).

```
======================================================================
RINGKASAN HASIL PENELITIAN
======================================================================

📊 DATASET:
  • Total data           : 502 mahasiswa
  • Jumlah fitur         : 10 variabel
  • Training set         : 401 data (79.9%)
  • Testing set          : 101 data (20.1%)

🤖 MODEL:
  • Algoritma            : Logistic Regression
  • Jenis                : Supervised Learning - Binary Classification
  • Preprocessing        : Label Encoding + StandardScaler
  • Cross-Validation     : 0.9826 (5-Fold CV)

📈 PERFORMA MODEL:
  • Accuracy             : 1.0000 (100.00%)
  • Precision            : 1.0000 (100.00%)
  • Recall               : 1.0000 (100.00%)
  • F1-Score             : 1.0000 (100.00%)
  • ROC AUC Score        : 1.0000
  • Baseline Accuracy    : 0.5050 (50.50%)
  • Improvement          : +49.50%

📉 CONFUSION MATRIX:
  • True Negative (TN)   : 50 data
  • False Positive (FP)  : 0 data
  • False Negative (FN)  : 0 data
  • True Positive (TP)   : 51 data

🎯 FITUR PALING BERPENGARUH (Top 3):
  1. Have you ever had suicidal thoughts ? :   3.2975 (↑ Meningkatkan)
  2. Academic Pressure                     :   3.0820 (↑ Meningkatkan)
  3. Age                                   :  -2.0376 (↓ Menurunkan)

======================================================================
✓ ANALISIS SELESAI
======================================================================
```

3.8.11 Proses penyimpanan model

Bagian kode ini menunjukkan proses penyimpanan model Logistic Regression, scaler, dan hasil evaluasi menggunakan modul pickle di Python untuk memastikan model dapat digunakan kembali tanpa pelatihan ulang. Model yang telah dilatih disimpan kedalam file logistic_regression_model.pkl, sedangkan StandardScaler disimpan dalam standard_scaler.pkl agar proses standarisasi pada data baru tetap konsisten dengan data

pelatihan. Selain itu, hasil evaluasi seperti *accuracy*, *precision*, *recall*, *F1-score*, *ROC AUC score*, *confusion matrix*, *cross-validation scores*, dan *koefisien fitur* juga disimpan dalam hasil_evaluasi.pkl sebagai dokumentasi kinerja model. Di akhir kode, terdapat perintah *print* yang menampilkan pesan keberhasilan untuk memastikan semua file tersimpan dengan benar. Secara keseluruhan, bagian ini mencerminkan praktik yang baik dalam *machine learning pipeline* karena menjamin reusability, konsistensi preprocessing, dan kemudahan penerapan model pada sistem atau aplikasi nyata.

```
# Simpan model dan scaler
import pickle

# Simpan model
with open('logistic_regression_model.pkl', 'wb') as f:
    pickle.dump(model, f)

# Simpan scaler
with open('standard_scaler.pkl', 'wb') as f:
    pickle.dump(scaler, f)

# Simpan hasil evaluasi
hasil_evaluasi = {
    'accuracy': accuracy,
    'precision': precision,
    'recall': recall,
    'f1_score': f1,
    'roc_auc': roc_auc,
    'confusion_matrix': cm.tolist(),
    'cv_scores': cv_scores.tolist(),
    'feature_coefficients': coefficients.to_dict()
}

with open('hasil_evaluasi.pkl', 'wb') as f:
    pickle.dump(hasil_evaluasi, f)

print("✓ Model berhasil disimpan: logistic_regression_model.pkl")
print("✓ Scaler berhasil disimpan: standard_scaler.pkl")
print("✓ Hasil evaluasi berhasil disimpan: hasil_evaluasi.pkl")
```

```
✓ Model berhasil disimpan: logistic_regression_model.pkl
✓ Scaler berhasil disimpan: standard_scaler.pkl
✓ Hasil evaluasi berhasil disimpan: hasil_evaluasi.pkl
```

**Progress Project IV - 26/11/2025**

## 3.9 Perbandingan Model

### 3.9.1 Model Random Forest

Pada tahap ini, membangun model menggunakan algoritma Random Forest, yaitu salah satu metode machine learning yang menggabungkan banyak pohon keputusan (decision tree) untuk meningkatkan akurasi prediksi dan mengurangi risiko overfitting. Model dikonfigurasi dengan 100 pohon dan kedalaman maksimum 10, serta menggunakan semua inti prosesor agar proses pelatihan lebih efisien. Kemudian, model dilatih dengan data latih yang telah diskalakan, sehingga setiap pohon dalam ensemble ini belajar dari pola pada data yang sudah disiapkan. Pemilihan parameter ini bertujuan agar model bisa mengenali karakteristik data secara optimal tanpa menjadi terlalu kompleks.

```
# Inisialisasi Random Forest
rf_model = RandomForestClassifier(
    n_estimators=100,      # Jumlah decision trees
    max_depth=10,          # Kedalaman maksimal tree
    random_state=42,
    n_jobs=-1              # Gunakan semua CPU core
)

# Training model
print("\n🌲 Training Random Forest...")
rf_model.fit(X_train_scaled, y_train)
print("✓ Random Forest berhasil dilatih!")
```

```
...
🌲 Training Random Forest...
✓ Random Forest berhasil dilatih!
```

### 3.9.2 Evaluasi Model Random Forest

Pada tahap evaluasi, model Random Forest menunjukkan kinerja yang sangat baik berdasarkan beberapa metrik utama, dengan nilai akurasi sebesar 92.08%, precision 89.09%, recall 96.08%, F1-score 92.45%, dan ROC AUC 0.9812. Nilai recall yang tinggi berarti model sangat baik dalam mendeteksi kasus positif (misalnya, individu dengan depresi), sedangkan precision yang juga cukup tinggi menunjukkan error tipe False Positive cukup minimal. F1-score yang mendekati nilai recall dan precision

memperlihatkan keseimbangan kinerja model antara recall dan precision. Angka ROC AUC di atas 0.98 menandakan model mampu membedakan kelas positif dan negatif dengan sangat baik.

```
# Evaluasi Random Forest
rf_accuracy = accuracy_score(y_test, y_pred_rf)
rf_precision = precision_score(y_test, y_pred_rf)
rf_recall = recall_score(y_test, y_pred_rf)
rf_f1 = f1_score(y_test, y_pred_rf)
rf_roc_auc = roc_auc_score(y_test, y_pred_proba_rf[:, 1])

print("="*60)
print("HASIL EVALUASI RANDOM FOREST")
print("="*60)
print(f"Accuracy  : {rf_accuracy:.4f} ({rf_accuracy*100:.2f}%)")
print(f"Precision : {rf_precision:.4f} ({rf_precision*100:.2f}%)")
print(f"Recall    : {rf_recall:.4f} ({rf_recall*100:.2f}%)")
print(f"F1-Score  : {rf_f1:.4f} ({rf_f1*100:.2f}%)")
print(f"ROC AUC   : {rf_roc_auc:.4f}")
print("="*60)
```

```
============================================================
HASIL EVALUASI RANDOM FOREST
============================================================
Accuracy  : 0.9208 (92.08%)
Precision : 0.8909 (89.09%)
Recall    : 0.9608 (96.08%)
F1-Score  : 0.9245 (92.45%)
ROC AUC   : 0.9812
============================================================
```

3.9.3 Visualisasi Confusion Matrix Model Random Forest

Berdasarkan visualisasi confusion matrix model Random Forest, model berhasil mengklasifikasikan data dengan akurasi sebesar 92.08%. Dari 101 data uji, terdapat 44 kasus "Tidak Depresi" yang diprediksi benar, 49 kasus "Depresi" yang juga diprediksi benar, 6 kasus False Positive (model memprediksi depresi, padahal sebenarnya tidak), dan 2 kasus False Negative (model memprediksi tidak depresi, padahal sebenarnya depresi). Dengan jumlah False Positive dan False Negative yang rendah, model dapat dianggap cukup akurat dalam membedakan kelompok depresi dan tidak depresi.

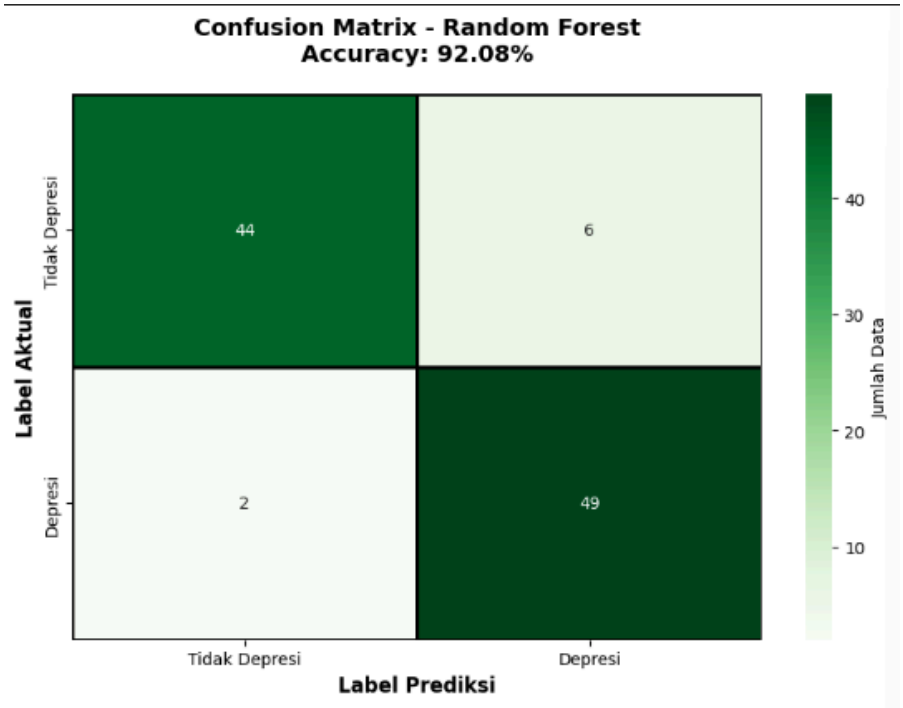


3.9.2 Model Support Vector Machine

Pada tahap ini dilakukan inisialisasi dan pelatihan model Support Vector Machine (SVM) dengan kernel rbf (Radial Basis Function), yang dikenal efektif untuk data yang pola pemisah antar kelasnya tidak linier. Parameter regularisasi diatur pada nilai 1.0 dan gamma disetel 'scale', sehingga model dapat menyesuaikan kompleksitasnya sesuai variasi data. Opsi probability=True digunakan agar model dapat menghasilkan estimasi probabilitas, yang berguna untuk aplikasi di mana tingkat keyakinan prediksi sangat penting, seperti klasifikasi depresi. Proses training dilakukan pada data latih yang sudah diskalakan, dengan hasil log menampilkan bahwa model berhasil dilatih tanpa kendala.

```python
# Inisialisasi SVM
svm_model = SVC(
    kernel='rbf',           # Radial Basis Function kernel
    C=1.0,                  # Regularization parameter
    gamma='scale',          # Kernel coefficient
    probability=True,       # Enable probability estimates
    random_state=42
)

# Training model
print("\n⚙️ Training SVM...")
svm_model.fit(X_train_scaled, y_train)
print("✓ SVM berhasil dilatih!")
```

```
⚙️ Training SVM...
✓ SVM berhasil dilatih!
```

3.9.2 Evaluasi Model Support Vector Machine

Pada tahap evaluasi, model **Support Vector Machine (SVM)** menunjukkan performa yang sangat baik berdasarkan metrik evaluasi yang dihitung. Model menghasilkan akurasi sebesar **95.05%**, precision **91.07%**, recall **100%**, F1-score **95.33%**, dan ROC AUC **0.9984**. Nilai recall yang mencapai **100%** menunjukkan bahwa model mampu mendeteksi seluruh sampel positif tanpa terlewat, sehingga tidak terjadi kesalahan *False Negative*. Precision sebesar 91.07% juga menandakan bahwa kesalahan *False Positive* relatif kecil. Kombinasi nilai recall dan precision yang tinggi menghasilkan F1-score sebesar 95.33%, menunjukkan keseimbangan kinerja model dalam mengklasifikasikan data secara konsisten. Selain itu, nilai ROC AUC yang mendekati 1.0 mengindikasikan bahwa model SVM memiliki kemampuan diskriminasi yang hampir sempurna dalam membedakan kelas positif dan negatif. Secara keseluruhan, hasil evaluasi ini memperlihatkan bahwa SVM merupakan model yang sangat efektif untuk digunakan pada skenario klasifikasi yang diuji.

```python
# Evaluasi SVM
svm_accuracy = accuracy_score(y_test, y_pred_svm)
svm_precision = precision_score(y_test, y_pred_svm)
svm_recall = recall_score(y_test, y_pred_svm)
svm_f1 = f1_score(y_test, y_pred_svm)
svm_roc_auc = roc_auc_score(y_test, y_pred_proba_svm[:, 1])

print("="*60)
print("HASIL EVALUASI SVM")
print("="*60)
print(f"Accuracy  : {svm_accuracy:.4f} ({svm_accuracy*100:.2f}%)")
print(f"Precision : {svm_precision:.4f} ({svm_precision*100:.2f}%)")
print(f"Recall    : {svm_recall:.4f} ({svm_recall*100:.2f}%)")
print(f"F1-Score  : {svm_f1:.4f} ({svm_f1*100:.2f}%)")
print(f"ROC AUC   : {svm_roc_auc:.4f}")
print("="*60)
```

```
============================================================
HASIL EVALUASI SVM
============================================================
Accuracy  : 0.9505 (95.05%)
Precision : 0.9107 (91.07%)
Recall    : 1.0000 (100.00%)
F1-Score  : 0.9533 (95.33%)
ROC AUC   : 0.9984
============================================================
```

3.9.3 Visualisasi Confusion Matrix Model Support Vector Machine

Berdasarkan visualisasi confusion matrix model SVM, model menunjukkan kinerja klasifikasi yang sangat baik dengan akurasi sebesar **95.05%**. Dari total 101 data uji, model berhasil memprediksi dengan benar **45 kasus "Tidak Depresi"** dan **51 kasus "Depresi"**. Terdapat **5 kasus False Positive**, yaitu ketika model memprediksi seseorang mengalami depresi padahal sebenarnya tidak, sementara **False Negative bernilai 0**, artinya tidak ada satu pun kasus depresi yang gagal terdeteksi oleh model. Kondisi ini memperlihatkan bahwa model SVM memiliki kemampuan deteksi yang sangat kuat terhadap kelas depresi, serta tingkat kesalahan yang sangat rendah secara keseluruhan. Dengan kesalahan prediksi yang minimal dan jumlah prediksi benar yang tinggi, model SVM dapat dianggap sangat efektif dalam membedakan data antara kategori depresi dan tidak depresi.

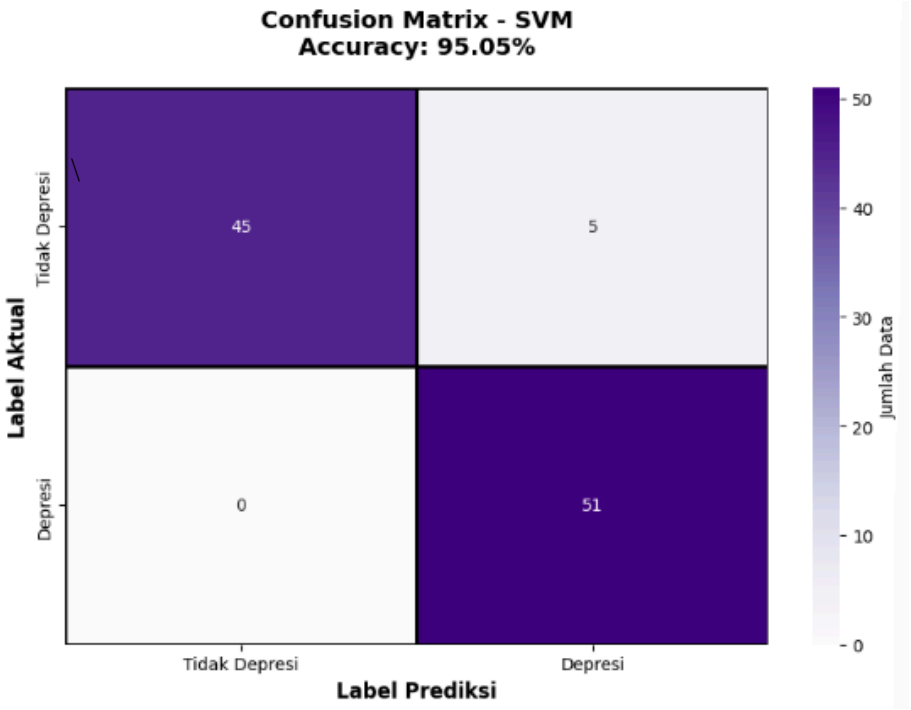


3.9.4 Perbandingan Performa Semua Model

Perbandingan performa tiga model Logistic Regression, Random Forest, dan SVM menunjukkan bahwa Logistic Regression consistently unggul di seluruh metrik dengan nilai sempurna pada accuracy, precision, recall, dan F1-score, yang mengindikasikan bahwa model ini mampu memisahkan data secara linear tanpa menghasilkan false positive maupun false negative. Sementara itu, SVM juga menunjukkan performa yang sangat baik dengan recall dan ROC AUC sempurna serta precision dan F1-score yang mendekati Logistic Regression, sehingga tetap menjadi model yang kuat dan stabil. Random Forest berada pada posisi terendah di antara ketiganya, dengan akurasi, precision, dan F1-score yang sedikit lebih rendah akibat adanya variasi prediksi antar pohon serta beberapa kesalahan pada kelas positif, meskipun recall dan ROC AUC-nya tetap tinggi. Secara keseluruhan, hasil ini memperlihatkan bahwa Logistic Regression menjadi model paling optimal, diikuti oleh SVM dan kemudian Random Forest.

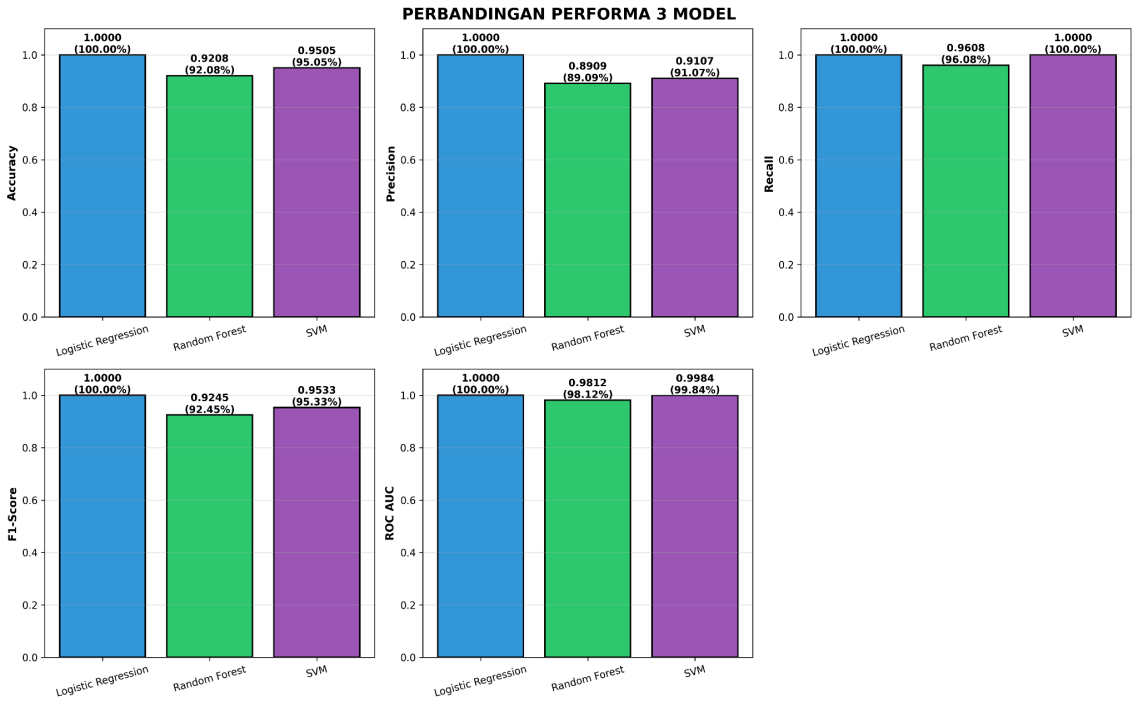


Dapat disimpulkan bahwa setelah menguji dengan beberapa model lainya tetap model logistic regression akan dipilih menjadi model utama dalam project ini.

# BAB IV

# Hasil dan Pembahasan

## 4.1 Hasil Analisis Data Survei Mahasiswa

Data survei pada penelitian ini diperoleh dari 10 mahasiswa Politeknik Caltex Riau melalui aplikasi Android yang dikembangkan. Data tersebut mencakup variabel demografis, akademik, psikologis, gaya hidup, serta kondisi finansial mahasiswa. Analisis pada subbab ini difokuskan pada hubungan antar variabel terhadap kondisi depresi berdasarkan hasil survei.

Karena jumlah responden relatif terbatas, analisis dilakukan secara deskriptif, dengan meninjau pola dan kecenderungan hubungan antar variabel, tanpa melakukan pengujian statistik inferensial.

### 4.1.1 Distribusi Kondisi Depresi

Berdasarkan hasil survei, diperoleh distribusi kondisi depresi sebagaimana ditunjukkan pada Tabel 4.1

**Tabel 4.1 Distribusi Kondisi Depresi Mahasiswa**

| Kondisi | Jumlah Responden | Persentase |
|---|---|---|
| Depresi | 2 | 20% |
| Tidak Depresi | 8 | 80% |
| **Total** | **10** | **100%** |

Hasil ini menunjukkan bahwa sebagian responden memiliki indikasi depresi, sehingga memungkinkan dilakukan analisis hubungan variabel terhadap kondisi tersebut.

### 4.1.2 Hubungan Variabel Akademik dengan Depresi

Hasil survei menunjukkan bahwa mahasiswa dengan kepuasan studi rendah dan tekanan akademik sedang hingga tinggi lebih banyak ditemukan pada kelompok yang

terindikasi depresi. Sebaliknya, mahasiswa dengan tingkat kepuasan studi tinggi cenderung tidak menunjukkan indikasi depresi.

Temuan ini mengindikasikan adanya hubungan negatif antara kepuasan studi dan depresi, serta hubungan positif antara tekanan akademik dan depresi dalam data survei yang dikumpulkan.

### 4.1.3 Hubungan Variabel Psikologis dengan Depresi

Variabel psikologis, khususnya riwayat pikiran bunuh diri, menunjukkan hubungan yang paling kuat terhadap kondisi depresi. Seluruh responden yang terindikasi depresi memiliki riwayat pikiran bunuh diri, sedangkan responden yang tidak pernah mengalami pikiran tersebut mayoritas tidak terindikasi depresi.

Selain itu, riwayat gangguan mental dalam keluarga juga ditemukan lebih sering pada kelompok depresi, meskipun hubungannya tidak sekuat variabel psikologis utama.

### 4.1.4 Hubungan Variabel Finansial dan Gaya Hidup

Mahasiswa dengan tingkat stres finansial tinggi cenderung memiliki indikasi depresi lebih besar dibandingkan mahasiswa dengan stres finansial rendah. Hal ini menunjukkan bahwa faktor ekonomi berperan sebagai pemicu tambahan terhadap kondisi mental mahasiswa.

Pada aspek gaya hidup, responden yang terindikasi depresi umumnya memiliki durasi tidur yang lebih pendek. Namun, pola makan tidak menunjukkan hubungan yang konsisten terhadap depresi pada data survei ini.

### 4.1.5 Pembahasan Hubungan Antar Variabel

Berdasarkan hasil analisis deskriptif, variabel yang menunjukkan hubungan paling jelas terhadap depresi mahasiswa adalah riwayat pikiran bunuh diri, kepuasan studi, dan stres finansial. Sementara itu, tekanan akademik dan durasi tidur berperan sebagai faktor pendukung. Variabel demografis seperti usia dan jenis kelamin tidak menunjukkan hubungan yang signifikan dalam data survei ini.

Hasil ini menunjukkan bahwa faktor psikologis dan akademik memiliki peran yang lebih dominan dibandingkan faktor demografis dalam memengaruhi kondisi depresi mahasiswa.

## 4.2 Hasil Implementasi Aplikasi Android

Aplikasi Android dikembangkan sebagai media pengumpulan data survei sekaligus sebagai sarana implementasi model machine learning. Aplikasi ini memungkinkan mahasiswa mengisi kuesioner yang mencakup seluruh variabel penelitian melalui antarmuka yang sederhana dan mudah digunakan.

### 4.2.1 Hasil Prediksi dan Visualisasi

Setelah data diinputkan, aplikasi menampilkan hasil prediksi risiko depresi berdasarkan model machine learning yang telah dilatih sebelumnya. Hasil ini ditampilkan dalam bentuk informasi yang mudah dipahami oleh pengguna.

📸 *(Screenshot 2: Tampilan hasil prediksi risiko depresi pada aplikasi)*

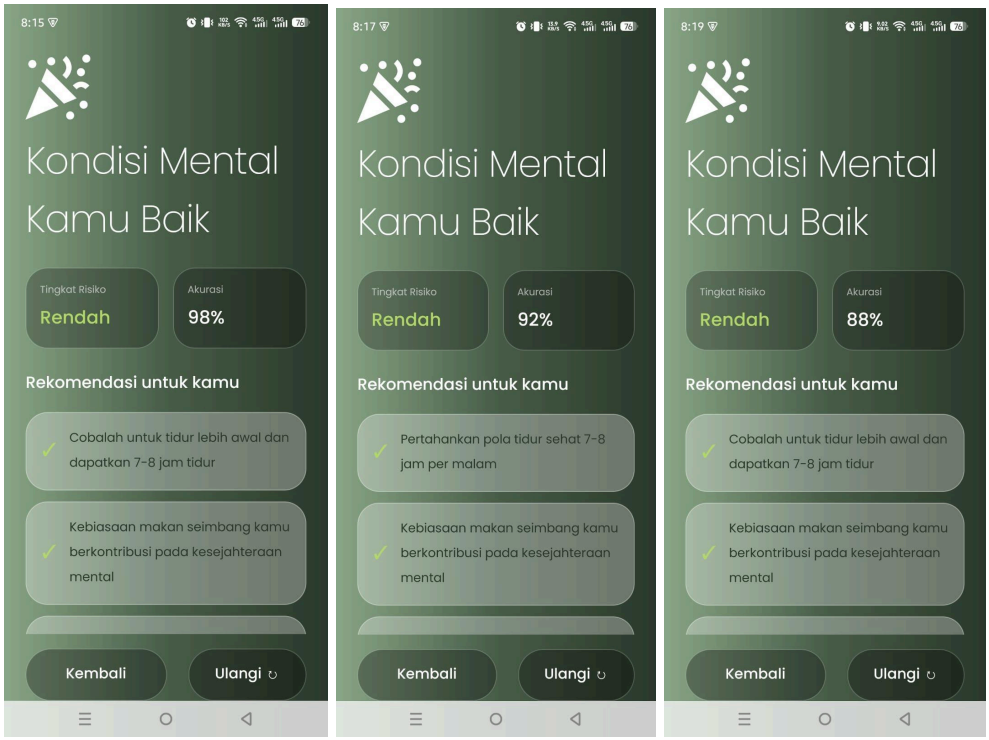

8:23
Kondisi Mental Kamu Baik
Tingkat Risiko
Rendah
Akurasi
90%
Rekomendasi untuk kamu
Cobalah untuk tidur lebih awal dan dapatkan 7-8 jam tidur
Kebiasaan makan seimbang kamu berkontribusi pada kesejahteraan mental
Kembali
Ulangi

8:26
Risiko Depresi Terdeteksi
Tingkat Risiko
Rendah
Akurasi
56%
Rekomendasi untuk kamu
Pertimbangkan berbicara dengan konselor kampus atau profesional kesehatan mental segera
Prioritaskan tidur 7-8 jam setiap malam - kualitas tidur sangat penting untuk kesehatan mental
Kembali
Ulangi

8:25
Kondisi Mental Kamu Baik
Tingkat Risiko
Rendah
Akurasi
76%
Rekomendasi untuk kamu
Cobalah untuk tidur lebih awal dan dapatkan 7-8 jam tidur
Kebiasaan makan seimbang kamu berkontribusi pada kesejahteraan mental
Kembali
Ulangi

8:21
Kondisi Mental Kamu Baik
Tingkat Risiko
Rendah
Akurasi
100%
Rekomendasi untuk kamu
Pertahankan pola tidur sehat 7-8 jam per malam
Teruskan tingkat kepuasan studi kamu saat ini
Pertimbangkan olahraga teratur
Kembali
Ulangi

8:32
Kondisi Mental Kamu Baik
Tingkat Risiko
Rendah
Akurasi
100%
Rekomendasi untuk kamu
Cobalah untuk tidur lebih awal dan dapatkan 7-8 jam tidur
Kebiasaan makan seimbang kamu berkontribusi pada kesejahteraan mental
Kembali
Ulangi

8:33
Risiko Depresi Terdeteksi
Tingkat Risiko
Tinggi
Akurasi
100%
Rekomendasi untuk kamu
Pertimbangkan berbicara dengan konselor kampus atau profesional kesehatan mental segera
Prioritaskan tidur 7-8 jam setiap malam - kualitas tidur sangat penting untuk kesehatan mental
Kembali
Ulangi

4.2.3 Hasil Pengujian pada Mahasiswa

Aplikasi diuji coba pada 10 mahasiswa Politeknik Caltex Riau. Hasil pengujian menunjukkan bahwa aplikasi mampu:

1. Menerima input data pengguna dengan baik,
2. Memproses data sesuai dengan variabel penelitian,
3. Menampilkan hasil prediksi risiko depresi secara konsisten.

Hasil survei yang diperoleh melalui aplikasi ini kemudian digunakan sebagai dasar analisis hubungan antar variabel pada Subbab 4.1.

4.2.4 Pembahasan Implementasi

Berdasarkan hasil pengujian, aplikasi Android berhasil menjalankan fungsinya sebagai alat bantu skrining awal kondisi depresi mahasiswa. Pengujian pada 10 responden bertujuan untuk memvalidasi fungsionalitas sistem, bukan untuk melakukan generalisasi hasil pada populasi yang lebih luas.

# BAB V

# KESIMPULAN DAN SARAN

## 5.1 Kesimpulan

Berdasarkan hasil pengolahan data, pemodelan *machine learning*, serta pengujian sistem menggunakan data survei mahasiswa, dapat disimpulkan sebagai berikut:

1. Model machine learning yang dibangun mampu melakukan klasifikasi risiko depresi dengan baik berdasarkan variabel akademik, psikologis, dan gaya hidup mahasiswa. Model Logistic Regression menunjukkan performa yang stabil serta konsisten pada proses evaluasi.
2. Beberapa variabel memiliki pengaruh yang lebih dominan terhadap prediksi depresi, terutama:
    - *Suicidal thoughts* (riwayat pikiran bunuh diri),
    - *Study satisfaction* (kepuasan studi),
    - *Academic pressure* dan *financial stress*.

      Hal ini dibuktikan melalui nilai koefisien model Logistic Regression yang menunjukkan kontribusi signifikan variabel-variabel tersebut terhadap hasil prediksi.
3. Hubungan antar variabel dan depresi bersifat logis dan konsisten dengan teori, di mana variabel psikologis dan akademik memberikan pengaruh yang lebih kuat dibandingkan variabel demografis seperti usia dan jenis kelamin.
4. Proses *preprocessing* data, termasuk *encoding*, *scaling*, dan transformasi variabel kategorikal, berperan penting dalam meningkatkan kinerja model dan memastikan konsistensi antara data pelatihan dan data pengujian dari aplikasi Android.
5. Implementasi model ke dalam aplikasi Android berhasil dilakukan, di mana data input pengguna dapat diproses oleh model machine learning dan menghasilkan prediksi risiko depresi secara real-time. Hal ini menunjukkan bahwa model tidak hanya valid secara teoritis, tetapi juga dapat digunakan dalam sistem nyata.

6. Pengujian menggunakan data survei 10 mahasiswa bersifat pengujian implementasi sistem, sehingga hasil prediksi digunakan untuk memverifikasi kesesuaian model dengan data baru, bukan untuk penarikan kesimpulan statistik populasi.

## 5.2 Saran

Untuk pengembangan penelitian dan sistem machine learning di masa mendatang, beberapa saran berikut dapat dipertimbangkan:

1. Menambah jumlah dan variasi data latih, sehingga model dapat mempelajari pola yang lebih kompleks dan menghasilkan prediksi yang lebih robust serta generalizable.
2. Melakukan eksplorasi algoritma machine learning lanjutan, seperti Gradient Boosting atau Neural Network, untuk dibandingkan dengan Logistic Regression dari sisi performa dan kompleksitas model.
3. Melakukan feature selection atau feature importance analysis, agar variabel yang kurang berpengaruh dapat dieliminasi dan model menjadi lebih efisien serta mudah diinterpretasikan.
4. Melakukan hyperparameter tuning secara sistematis, misalnya menggunakan Grid Search atau Random Search, untuk mengoptimalkan kinerja model yang digunakan.
5. Menerapkan evaluasi tambahan, seperti ROC-AUC dan precision-recall, agar kualitas model dapat dianalisis lebih mendalam terutama pada kasus ketidakseimbangan kelas.
6. Mengembangkan mekanisme pembaruan model (*model retraining*), sehingga sistem dapat menyesuaikan diri dengan data baru yang terus bertambah dari penggunaan aplikasi Android.

# DAFTAR PUSTAKA


1. Jatmiko, N. A., Farhanhr, Okta, D., & Saifuddin, N. (2023). *Depression Student Dataset* [Dataset]. Kaggle. https://www.kaggle.com/datasets/
2. Basuki, R. S. P., & Abbas, M. S. (2025, January). *Pembangunan model prediksi depresi pelajar berdasarkan faktor lingkungan dan akademis* [Preprint]. Virginia Tech. https://doi.org/10.13140/RG.2.2.24583.71844/1
3. Dirgayunita, A. (2016). Depresi: Ciri, penyebab dan penangannya. *Journal An-Nafs: Kajian Penelitian Psikologi, 1*(1), 1–14. https://doi.org/10.33367/psi.v1i1.235
4. Summerfield, D. (2012). *Depression in the workplace: What is depression?* British Journal of Psychiatry, 201(4), 327. https://doi.org/10.1192/bjp.201.4.327\
5. Sumantiawan, D. I., Amaliyah, S., Narulita, S., Kholilurrahman, M., & Suharmanto, A. Y. (2024). *Analisis faktor status depresi kehidupan mahasiswa menggunakan machine learning*. Digital Transformation Technology, 4(1), 705–713. https://doi.org/10.47709/digitech.v4i1.4577